人工智能与自动化学院

模式识别与机器学习

授课教师：杨卫东　胡静

L5-1



第六讲　非线性变换（*Nonlinear Transformation*）

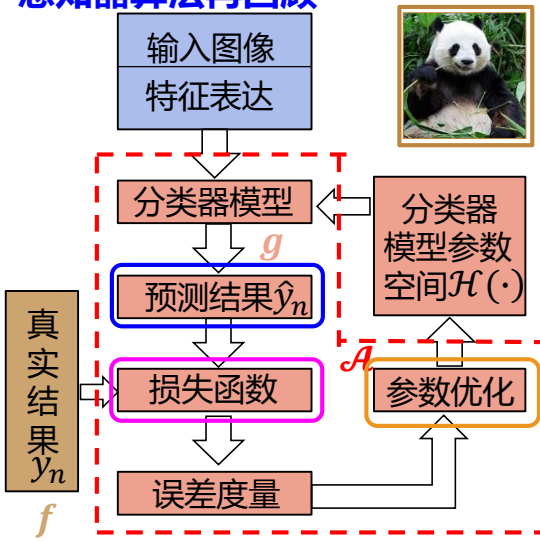
6.1 线性不可分问题（*Nonlinear Data Problem*）

6.2 非线性变换（*Nonlinear Transform*）

6.3 知识拓展（*Knowledge Extension* ）

6.1 线性不可分问题

感知器算法再回顾



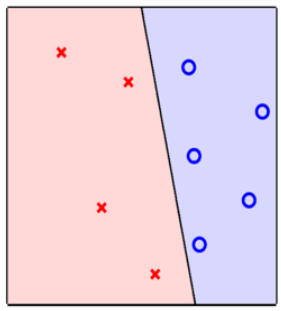
$$\hat{y}_{n(t)} = \text{sign}(\boldsymbol{w}_t^T \mathbf{x}_{n(t)})$$

算法收敛：

$$L_{in} = \sum_{n=1}^{N} [\![y_n \neq \hat{y}_n]\!] = 0$$

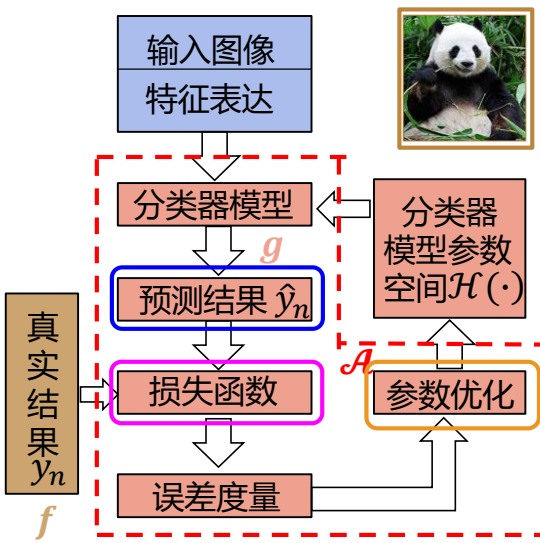
$$\boldsymbol{w}_{t+1} = \boldsymbol{w}_t + y_n \mathbf{x}_{n(t)}$$

线性可分



- 设置初始分类面(权重)$\boldsymbol{w}_0$
- 如果有样本分错，就修正权重

6.1 线性不可分问题



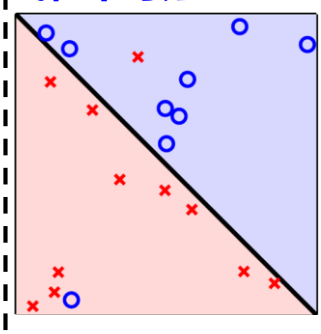
$$\hat{y}_{n(t)} = \text{sign}(\boldsymbol{w}_t^T \mathbf{x}_{n(t)})$$

算法停止条件：

$$L_{in} = \underset{\boldsymbol{w}}{argmin} \sum_{n=1}^{N} [\![y_n \neq \hat{y}_n]\!]$$

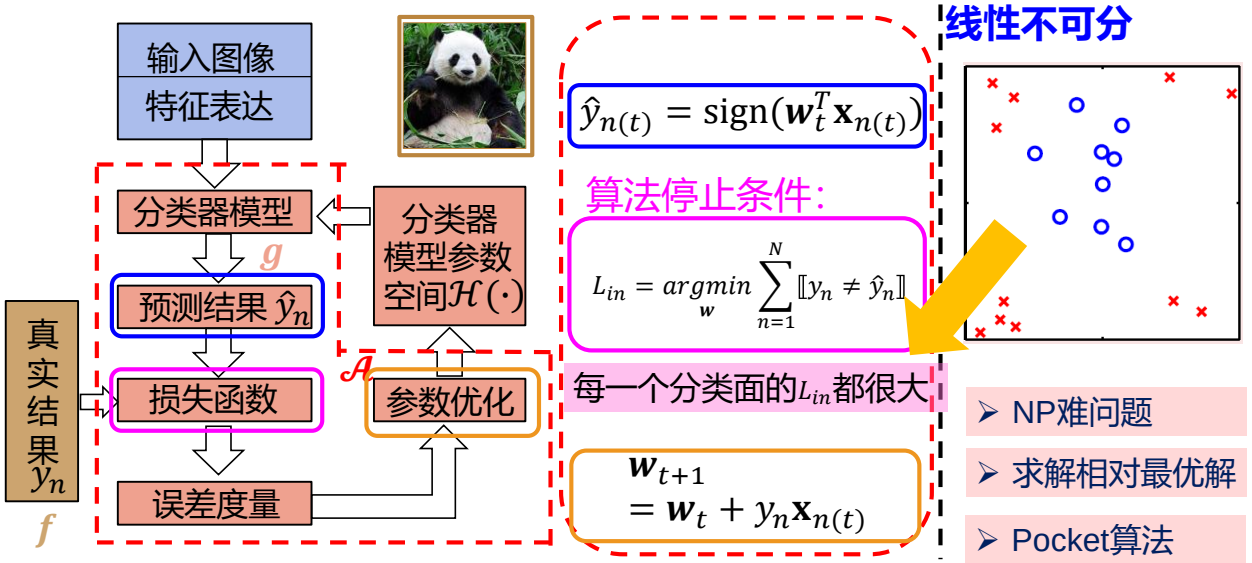
$$\boldsymbol{w}_{t+1} = \boldsymbol{w}_t + y_n \mathbf{x}_{n(t)}$$

线性不可分



- NP难问题
- 求解相对最优解
- Pocket算法

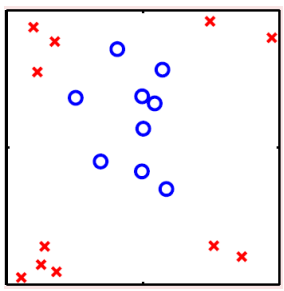
6.1 线性不可分问题



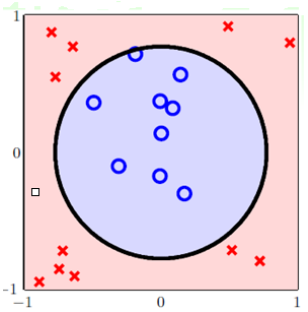
- NP难问题
- 求解相对最优解
- Pocket算法

6.1 线性不可分问题

如何突破线性分类限制



线性不可分



圆圈可分

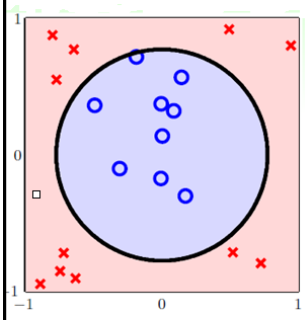
$$h_{sep}(\mathbf{x}) = sign(-x_1^2 - x_2^2 + 0.6)$$

6.1 线性不可分问题

圆圈可分与线性可分

$$h_{sep}(\mathbf{x}) = sign(0.6 \cdot 1 + (-1) \cdot x_1^2 + (-1) \cdot x_2^2)$$

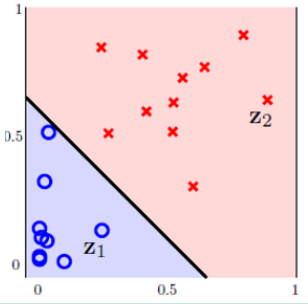
$$= sign(\tilde{w}_0 z_0 + \tilde{w}_1 z_1 + \tilde{w}_2 z_2) = sign(\tilde{\boldsymbol{w}}^T \mathbf{z})$$



$\{(\mathbf{x}_n, y_n)\}$圆圈可分 ➡ $\{(\mathbf{z}_n, y_n)\}$线性可分

$$\mathbf{x} \in \mathcal{X} \xrightarrow{\Phi} \mathbf{z} \in \mathcal{Z}$$

$\boldsymbol{\Phi}$：非线性特征变换



6.1 线性不可分问题

利用二次多项式的一般表达将样本 $\mathbf{x}$ 从 $\mathcal{X}$ 空间变换到 $\mathcal{Z}$ 空间

$$\boldsymbol{\phi}_2(\mathbf{x}) = (1, x_1, \ldots, x_d, x_1^2, x_1 x_2, \ldots, x_d^2)^T$$

如果样本 $\mathbf{x}$ 是 2 维特征，则： $\boldsymbol{\phi}_2(\mathbf{x}) = (1, x_1, x_2, x_1^2, x_1 x_2, x_2^2)^T$

样本 $\mathbf{x}$ 从原来的 d 维特征空间变换到多少维特征空间?

$$\tilde{d} = 1 + d + d + C_d^2 = 1 + d + d + \binom{d}{2}$$

不放回的组合问题

$$= 1 + d + d + \frac{d(d-1)}{2} = 1 + \frac{d(d+3)}{2} = \frac{(d+2)(d+1)}{2}$$

6.1 线性不可分问题

利用二次多项式的一般表达将样本 $\mathbf{x}$ 从 $\mathcal{X}$ 空间变换到 $\mathcal{Z}$ 空间

$$\boldsymbol{\phi}_2(\mathbf{x}) = (1, x_1, \ldots, x_d, x_1^2, x_1x_2, \ldots, x_d^2)^T$$

如果样本 $\mathbf{x}$ 是 2 维特征，则： $\boldsymbol{\phi}_2(\mathbf{x}) = (1, x_1, x_2, x_1^2, x_1x_2, x_2^2)^T$

样本 $\mathbf{x}$ 从原来的 d 维特征空间变换到多少维特征空间?

$$\tilde{d} = 1 + d + d + C_d^2 = 1 + d + d + \binom{d}{2}$$

放回的组合问题

$$= 1 + d + d + \frac{d(d-1)}{2} = 1 + \frac{d(d+3)}{2} = \frac{(d+2)(d+1)}{2} = \binom{2+d}{2}$$

6.1 线性不可分问题

利用Q次多项式的一般表达将样本 $\mathbf{x}$ 从 $\mathcal{X}$ 空间变换到 $\mathcal{Z}$ 空间

$$\boldsymbol{\phi}_Q(\mathbf{x}) = (1, \underbrace{x_1, \ldots, x_d}_{\text{一次项}}, \underbrace{x_1^2, x_1x_2, \ldots, x_d^2}_{\text{二次项}}, \ldots, \underbrace{x_1^Q, x_1^{Q-1}x_2, \ldots, x_d^Q}_{\text{Q次项}})^T$$

样本 $\mathbf{x}$ 从原来的 d 维特征空间变换到多少维特征空间?

$$\tilde{d} = C_{Q+d}^Q = \binom{Q+d}{Q}$$

放回的组合问题

非线性变换使特征被升到高维空间

$$= \frac{(Q+d)!}{Q! \cdot d!} = \frac{(Q+d-1)(Q+d-2)\cdots(Q+1)}{d!} \Rightarrow Q^d$$

第六讲　非线性变换 (*Nonlinear Transformation*)

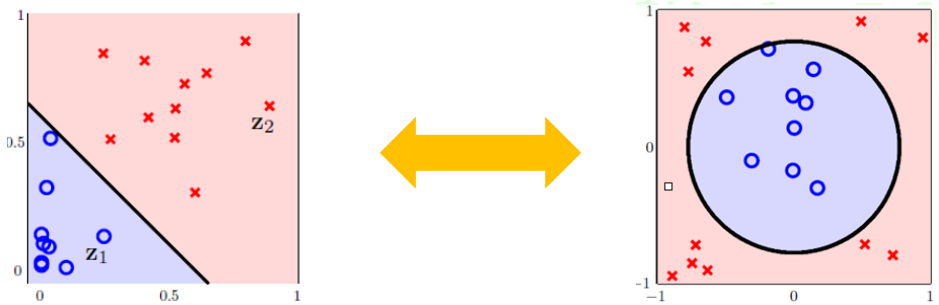
6.1 线性不可分问题（*Nonlinear Data Problem*）

6.2 非线性变换（*Nonlinear Transform*）

6.3 知识拓展（*Knowledge Extension* ）

6.2 非线性变换

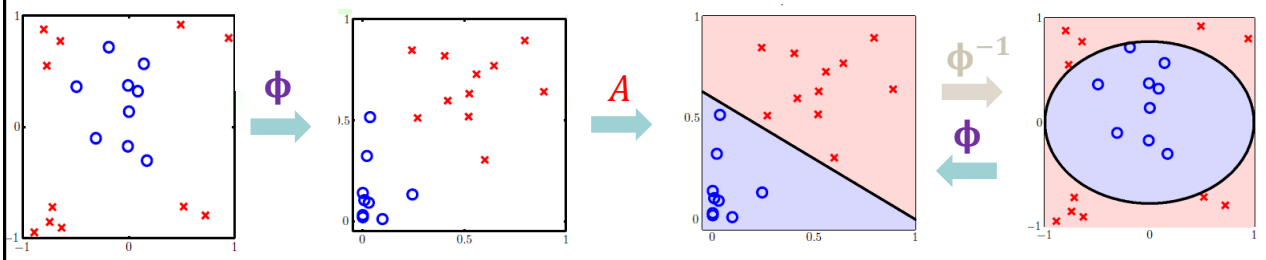
非线性变换的目的



通过非线性变换 $\boldsymbol{\Phi_Q}$ 使得训练样本集$\{(\boldsymbol{z_n} = \boldsymbol{\Phi_Q}\ (\mathbf{x_n}), y_n)\}$在$Z$ 空间找到好的分类面

6.2 非线性变换

非线性变换步骤



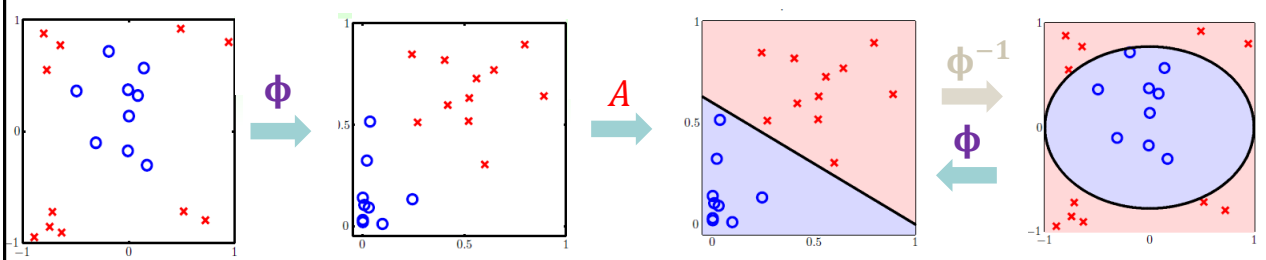
① 利用非线性变换 ϕ 将原始训练样本集$\{(\mathbf{x}_n, y_n)\}$变换到Z 空间$\{(\mathbf{z}_n = \phi(\mathbf{x}_n), y_n)\}$;

② 在数据集$\{(\mathbf{z}_n, y_n)\}$上选择合适的线性分类算法$\mathcal{A}$，得到最佳解 $\tilde{w}^*$

③ 返回分类结果： $g(\mathbf{x}) = sign(\tilde{w}^{*T}\mathbf{x})$

6.2 非线性变换

非线性模型 ➡ 非线性变换ϕ + 线性模型



线性模型不局限于二元分类；

通过非线性变换，可以方便地实现：二次PLA、三次PLA、更高次数多项式的PLA

二次回归、三次回归、更高次数回归。。。

6.2 非线性变换

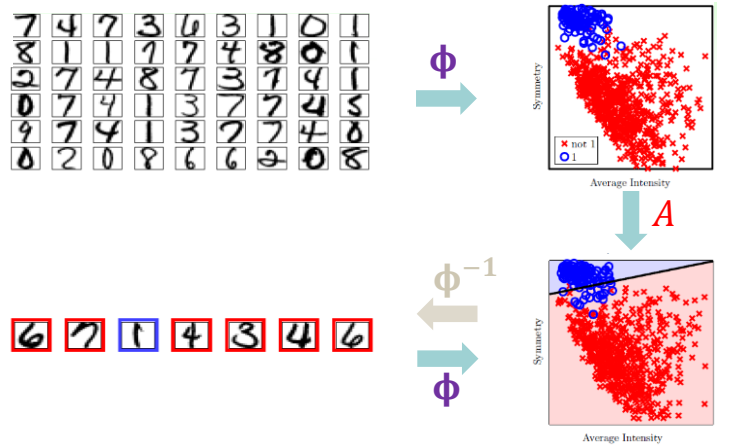
特征提取 → 特征变换 ϕ

非线性变换并不一定是多项式变换

图像原始像素值
raw (pixels)

领域知识
domain knowledge

具体特征
concrete (intensity, symmetry)



第六讲　非线性变换 (*Nonlinear Transformation*)

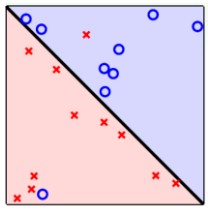
6.1 线性不可分问题 (*Nonlinear Data Problem*)

6.2 非线性变换 (*Nonlinear Transform*)

6.3 知识拓展 (*Knowledge Extension*)

6.3 知识拓展

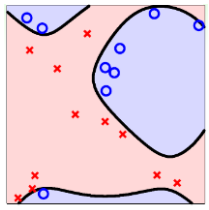
模型泛化能力讨论(Generalization Issue)



Φ_1 (original **x**)

$L_{in} \neq 0$

你认为哪个分类面更好?

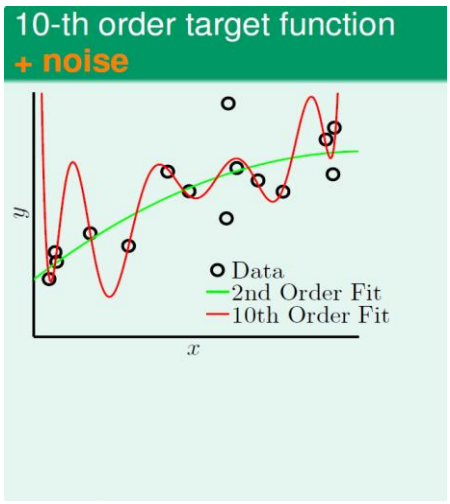


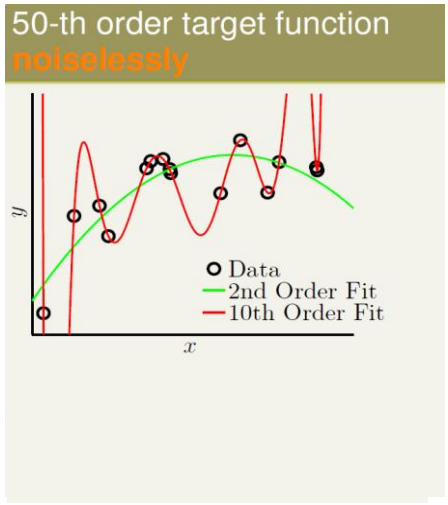
Φ_4

$L_{in} = 0$

6.3 知识拓展

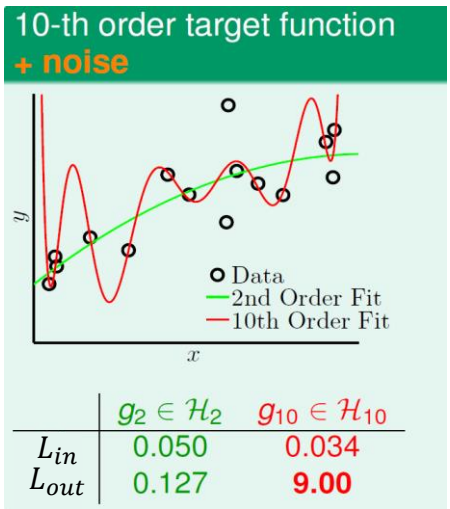
模型泛化能力讨论(Generalization Issue)



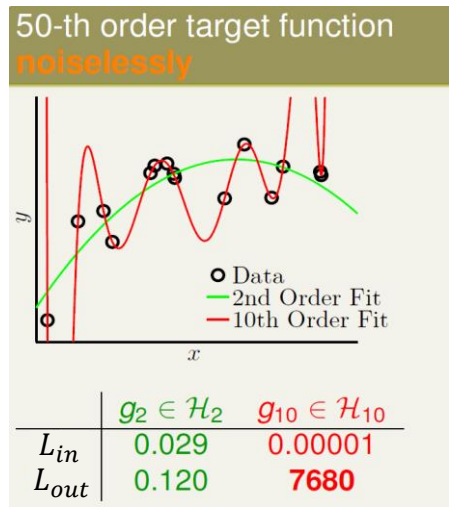


6.3 知识拓展

模型泛化能力讨论(Generalization Issue)

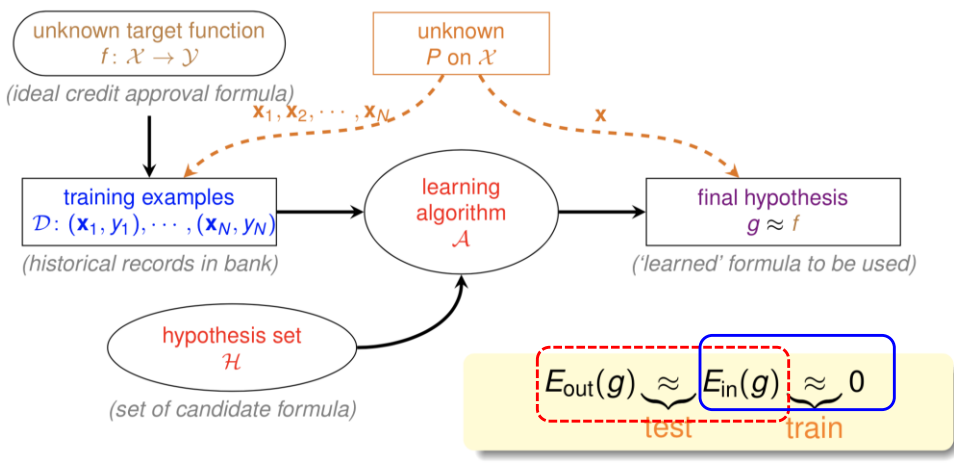


	$g_2 \in \mathcal{H}_2$	$g_{10} \in \mathcal{H}_{10}$
L_{in}	0.050	0.034
L_{out}	0.127	**9.00**



	$g_2 \in \mathcal{H}_2$	$g_{10} \in \mathcal{H}_{10}$
L_{in}	0.029	0.00001
L_{out}	0.120	**7680**

机器学习的过程



台湾大学林轩田-《机器学习基石Machine Learning Foundations 》

机器学习的过程

- 期望误差：E_out(g)，学到的假设g在除了训练样本外的其他所有样本(out-of-sample)上的损失，也称泛化误差
- 经验误差：E_in(g)，学到的假设g在训练样本(in-of-sample)上的损失

- 可学习条件，样本足够多
  （1）train过程，希望经验误差尽可能小
  （2）test过程，希望在真实环境中的期望误差与经验误差一致

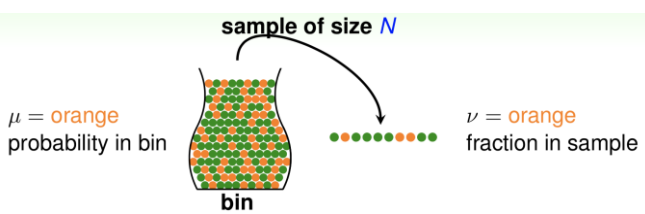
6.3 知识拓展

Hoffding`s Inequality （霍夫丁不等式，数学家）

- in big sample (N large), ν is probably close to μ (within ϵ)

$$\mathbb{P}\left[|\nu-\mu|>\epsilon\right] \leq 2\exp\left(-2\epsilon^2 N\right)$$

http://blog.csdn.net/qq_34993631



6.3 知识拓展

模型泛化能力讨论(Generalization Issue)

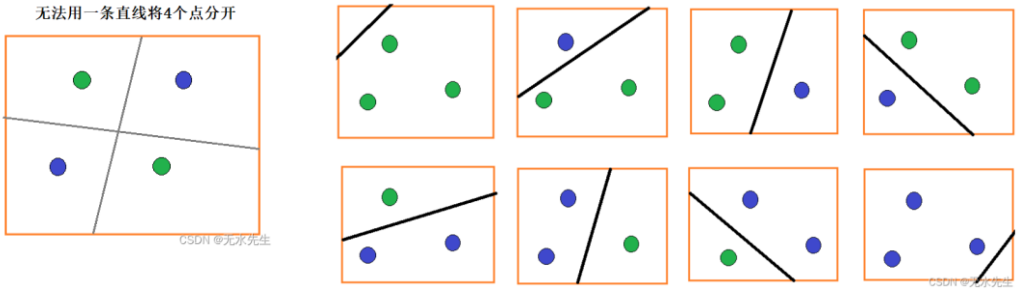
Vapnik-Chervonenkis (VC) Bound

For any $g = \mathcal{A}(\mathcal{D}) \in \mathcal{H}$ and 'statistical' large $\mathcal{D}$, for ~~$N \geq 2$~~, $d_{VC} \geq 2$

$$\underbrace{\mathbb{P}_{\mathcal{D}}\left[\left|E_{in}(g) - E_{out}(g)\right| > \epsilon\right]}_{\text{BAD}} \quad \leq \quad \underbrace{4(2N)^{d_{VC}} \exp\left(-\frac{1}{8}\epsilon^2 N\right)}_{\delta}$$

VC维

- 数据样本的属性维度d
- H个样本能够被函数集S中的函数按所有可能的2^H分开，正确二分类
- H个样本可以任意给出，无条件限制



d=2，H=3

6.3 知识拓展

Vapnik-Chervonenkis (VC) Bound

For any $g = \mathcal{A}(\mathcal{D}) \in \mathcal{H}$ and 'statistical' large $\mathcal{D}$, for ~~$N \geq 2$~~, $d_{\text{VC}} \geq 2$

$$\mathbb{P}_{\mathcal{D}}\Big[\underbrace{|E_{\text{in}}(g) - E_{\text{out}}(g)| > \epsilon}_{\textbf{BAD}}\Big] \quad \leq \quad \underbrace{4(2N)^{d_{\text{VC}}} \exp\left(-\tfrac{1}{8}\epsilon^2 N\right)}_{\delta}$$

..., with probability $\geq 1 - \delta$, **GOOD**: $|E_{\text{in}}(g) - E_{\text{out}}(g)| \leq \epsilon$

$$\begin{aligned} \text{set} \quad \delta &= 4(2N)^{d_{\text{VC}}} \exp\left(-\tfrac{1}{8}\epsilon^2 N\right) \\ \tfrac{\delta}{4(2N)^{d_{\text{VC}}}} &= \exp\left(-\tfrac{1}{8}\epsilon^2 N\right) \\ \ln\left(\tfrac{4(2N)^{d_{\text{VC}}}}{\delta}\right) &= \tfrac{1}{8}\epsilon^2 N \\ \sqrt{\tfrac{8}{N}\ln\left(\tfrac{4(2N)^{d_{\text{VC}}}}{\delta}\right)} &= \epsilon \end{aligned}$$

6.3 知识拓展

Vapnik-Chervonenkis (VC) Bound

For any $g = \mathcal{A}(\mathcal{D}) \in \mathcal{H}$ and 'statistical' large $\mathcal{D}$, for ~~$N \geq 2$~~, $d_{\text{VC}} \geq 2$

$$\mathbb{P}_{\mathcal{D}}\Big[\underbrace{|E_{\text{in}}(g) - E_{\text{out}}(g)| > \epsilon}_{\textbf{BAD}}\Big] \quad \leq \quad \underbrace{4(2N)^{d_{\text{VC}}} \exp\left(-\tfrac{1}{8}\epsilon^2 N\right)}_{\delta}$$

..., with probability $\geq 1 - \delta$, **GOOD**!

$$\text{gen. error } |E_{\text{in}}(g) - E_{\text{out}}(g)| \quad \leq \quad \sqrt{\tfrac{8}{N}\ln\left(\tfrac{4(2N)^{d_{\text{VC}}}}{\delta}\right)}$$

$$E_{\text{in}}(g) - \sqrt{\tfrac{8}{N}\ln\left(\tfrac{4(2N)^{d_{\text{VC}}}}{\delta}\right)} \leq E_{\text{out}}(g) \leq E_{\text{in}}(g) + \sqrt{\tfrac{8}{N}\ln\left(\tfrac{4(2N)^{d_{\text{VC}}}}{\delta}\right)}$$

6.3 知识拓展

模型复杂度

with a high probability,

$$E_{\text{out}}(g) \le E_{\text{in}}(g) + \underbrace{\sqrt{\frac{8}{N}\ln\left(\frac{4(2N)^{d_{\text{VC}}}}{\delta}\right)}}_{\Omega(N,\mathcal{H},\delta)}$$

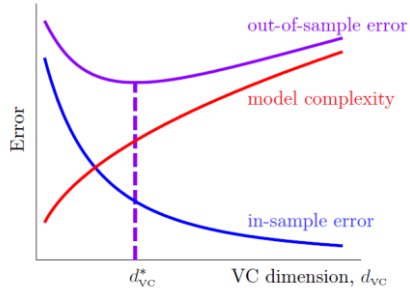
$\underbrace{\sqrt{\cdots}}_{\Omega(N,\mathcal{H},\delta)}$: penalty for **model complexity**

6.3 知识拓展

模型复杂度

with a high probability,

$$E_{\text{out}}(g) \le E_{\text{in}}(g) + \underbrace{\sqrt{\frac{8}{N}\ln\left(\frac{4(2N)^{d_{\text{VC}}}}{\delta}\right)}}_{\Omega(N,\mathcal{H},\delta)}$$

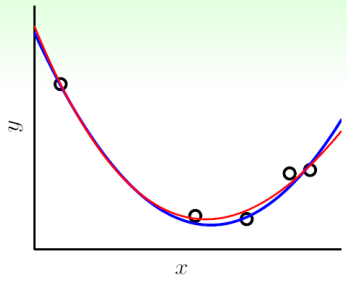


- $d_{\text{VC}} \uparrow$: $E_{\text{in}} \downarrow$ but $\Omega \uparrow$
- $d_{\text{VC}} \downarrow$: $\Omega \downarrow$ but $E_{\text{in}} \uparrow$
- best d_{VC}^* in the middle

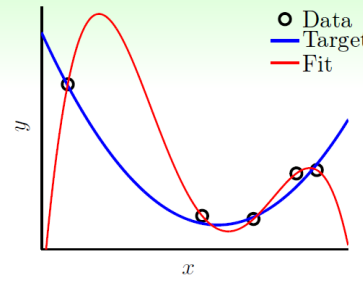
powerful $\mathcal{H}$ not always good!

6.3 知识拓展

泛化性能不好与过拟合(*Bad Generalization and Overfitting*)

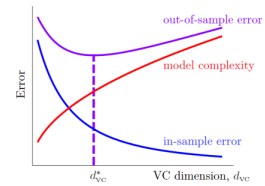


'good fit'



overfit

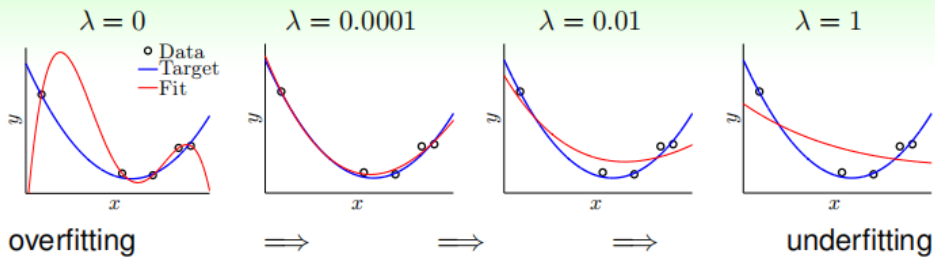
bad generalization: low E_{in}, high E_{out};
overfitting: lower E_{in}, higher E_{out}



6.3 知识拓展

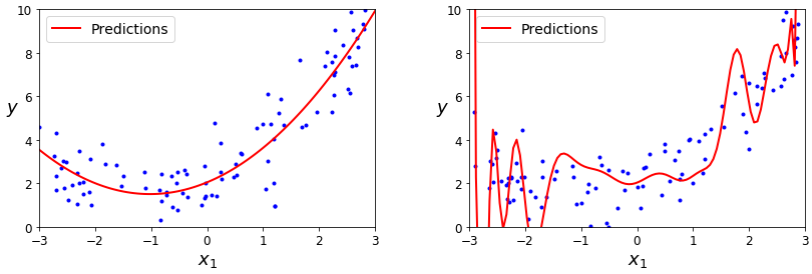
过拟合与正则化(*Overfitting and Regularization*)

$$\min_{\mathbf{w}} E_{aug}(\mathbf{w}) = E_{in}(\mathbf{w}) + \frac{\lambda}{N}\mathbf{w}^T\mathbf{w}$$



6.3 知识拓展

❖ 正则化(*Regularization*)



- 数据去噪
- 降维，减少特征，留取最重要的特征
- 惩罚不重要的特征的权重

第六讲　非线性变换 (*Nonlinear Transformation*)

6.1线性不可分问题 (Nonlinear Data Problem)

通过多项式变换后的数据集符合线性模型特点

6.2 非线性变换

利用$Z = \Phi(X)$变换后，可以方便地使用线性模型处理

6.3 知识拓展

VC Bound、模型复杂度、泛化能力、过拟合、正则化