人工智能与自动化学院

模式识别与机器学习

授课教师：杨卫东　胡静

L5-2



第七讲　线性支撑向量机 (*Linear Support Vector Machine*)

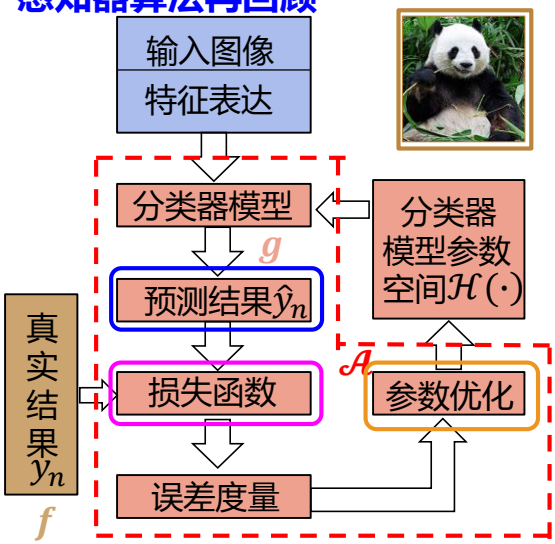
7.1 最大间隔分类面(*Large-Margin Separating Hyperplane*)

7.2 标准的最大间隔问题(*Standard Large-Margin Problem*)

7.3 支撑向量机(*Support Vector Machine*)

7.1 最大间隔分类面

感知器算法再回顾



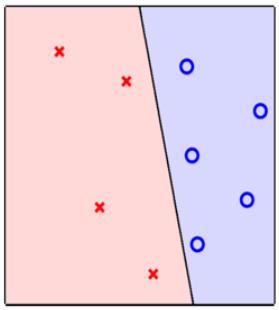
$$\hat{y}_{n(t)} = \text{sign}(\boldsymbol{w}_t^T \mathbf{x}_{n(t)})$$

算法收敛：

$$L_{in} = \sum_{n=1}^{N} [\![y_n \neq \hat{y}_n]\!] = 0$$

$$\boldsymbol{w}_{t+1} = \boldsymbol{w}_t + y_n \mathbf{x}_{n(t)}$$

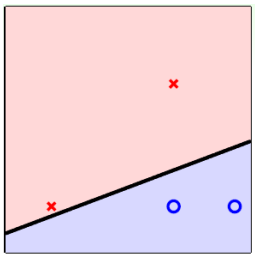
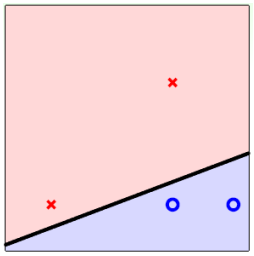
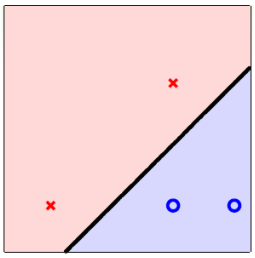
线性可分



- 设置初始分类面(权重)$\boldsymbol{w}_0$
- 如果有样本分错，就修正权重

7.1 最大间隔分类面

哪一个分类面最佳?

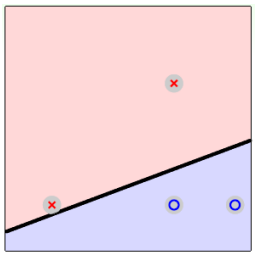
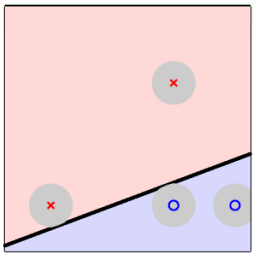
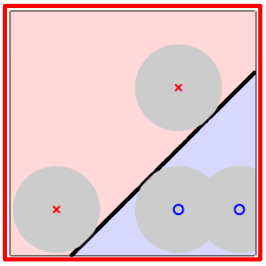




- 感知器算法能找出吗?
- VC bound?

$$E_{\text{out}}(\mathbf{w}) \leq \underbrace{E_{\text{in}}(\mathbf{w})}_{0} + \underbrace{\Omega(\mathcal{H})}_{d_{\text{VC}}=d+1}$$

7.1 最大间隔分类面

为什么会认为最右边的分类面最佳?

假设 $\mathbf{x} \approx \mathbf{x}_n + \Delta\mathbf{x}_n$, $\Delta\mathbf{x}_n \sim N(\mathbf{x}_n, \sigma_n)$

$\mathbf{x}_n$ 离分类面越远 ⇔ 容许σ_n越大，噪声的容忍度越大⇔不易出现过拟合

⇔ 更鲁棒分类面⇔ 对噪声的容忍度更大⇔离分类面最近的$\mathbf{x}_n$ 到分类面距离

最右边的最佳----因为离分类面最近的$\mathbf{x}_n$ 到分类面距离**最大**，对噪声最鲁棒

7.1 最大间隔分类面

对噪声鲁棒的分类面

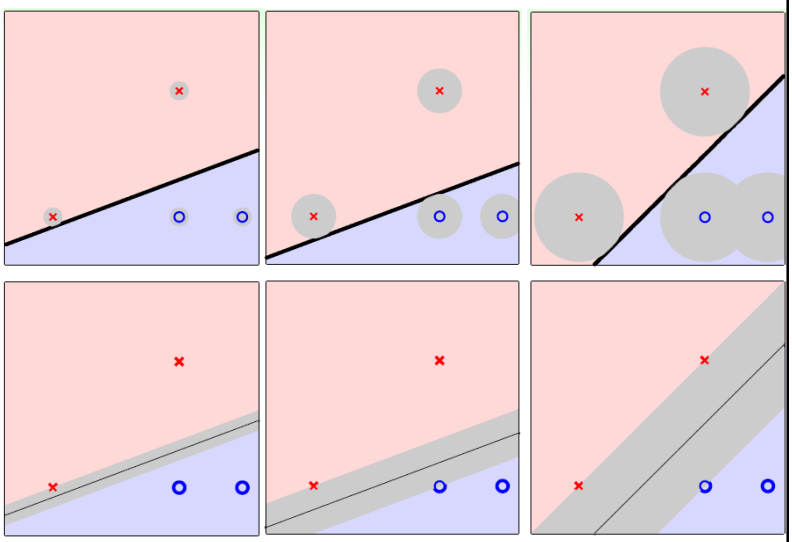
⇕

分类面到两边样本的距离要大

⇕

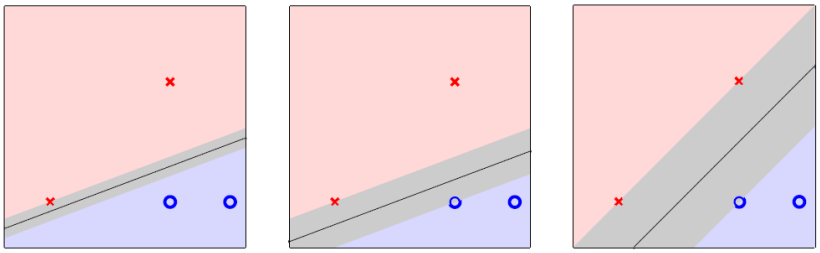
“胖胖”的分类面

算法的目的是如何找到“胖胖”的分类面



7.1 最大间隔分类面

“胖胖”的分类面



$$\max_{\mathbf{w}} \quad \text{fatness}(\mathbf{w})$$

$$\text{subject to} \quad \mathbf{w} \text{ classifies every } (\mathbf{x}_n, y_n) \text{ correctly}$$

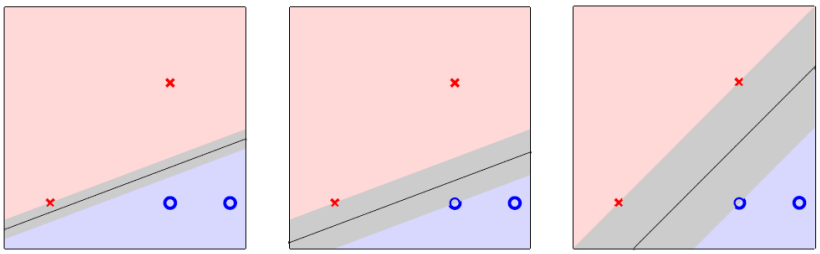
$$\text{fatness}(\mathbf{w}) = \min_{n=1,\ldots,N} \text{distance}(\mathbf{x}_n, \mathbf{w})$$

7.1 最大间隔分类面

“胖胖”的分类面

⇕

最大间隔分类面



$$\max_{\mathbf{w}} \quad \text{margin}(\mathbf{w})$$

$$\text{subject to} \quad \mathbf{w} \text{ classifies every } (\mathbf{x}_n, y_n) \text{ correctly}$$

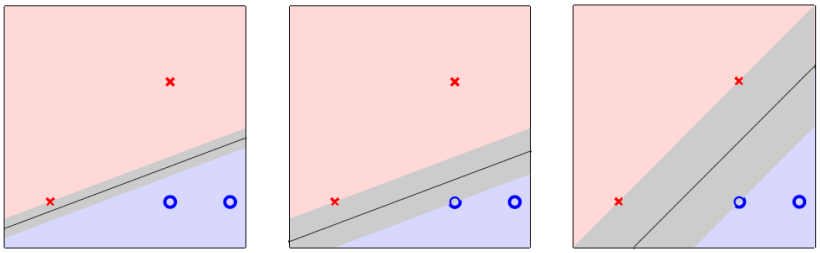
$$\text{margin}(\mathbf{w}) = \min_{n=1,\ldots,N} \text{distance}(\mathbf{x}_n, \mathbf{w})$$

7.1 最大间隔分类面

“胖胖”的分类面

⇕

最大间隔分类面



所有样本正确分类

⇕

$y_n = \text{sign}(\boldsymbol{w}^T\mathbf{x}_n)$

$$\max_{\mathbf{w}} \ \text{margin}(\mathbf{w})$$

subject to $\mathbf{w}$ classifies every $(\mathbf{x}_n, y_n)$ correctly

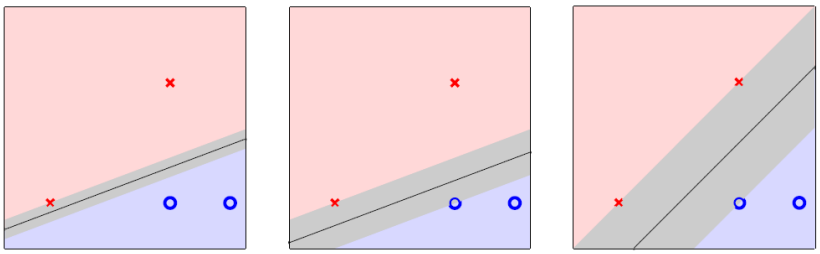
$$\text{margin}(\mathbf{w}) = \min_{n=1,\dots,N} \text{distance}(\mathbf{x}_n, \mathbf{w})$$

7.1 最大间隔分类面

“胖胖”的分类面

⇕

最大间隔分类面



所有样本正确分类

⇕

$y_n = \text{sign}(\boldsymbol{w}^T\mathbf{x}_n)$

$$\max_{\mathbf{w}} \ \text{margin}(\mathbf{w})$$

subject to every $y_n\mathbf{w}^T\mathbf{x}_n > 0$

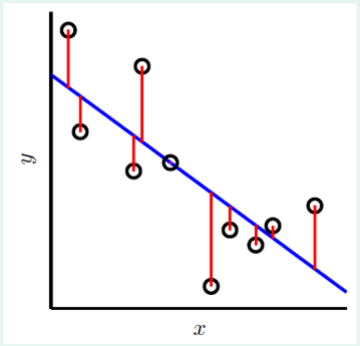
$$\text{margin}(\mathbf{w}) = \min_{n=1,\dots,N} \text{distance}(\mathbf{x}_n, \mathbf{w})$$

算法的目的是：如何找到“最大间隔”的分类面(*find largest-margin separating hyperplane*)

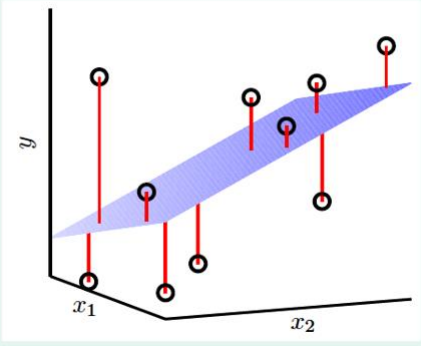
3.1 线性回归问题（引）

线性回归示例

$\mathbf{x} = (x) \in \mathbb{R}$



$\mathbf{x} = (x_1, x_2) \in \mathbb{R}^2$



回归问题：$y \in \mathbb{R}$

4.1 Fisher线性判别动机（引）

Fisher线性判别的目的：

- 在尽可能保留类别可区分性的前提下实现维数减少

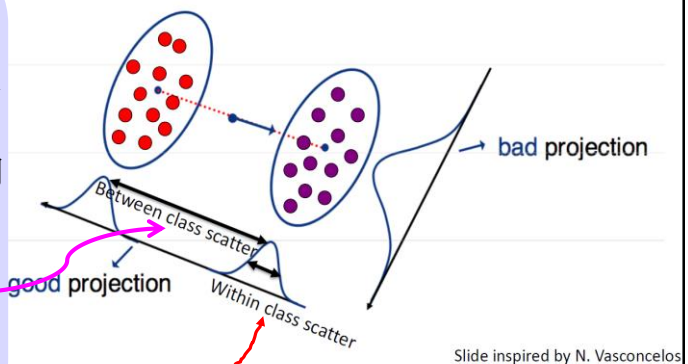
（*Perform dimensionality reduction "while preserving as much of the class discriminatory information as possible".*）

- 找到让类别最好区分的投影方向

（*Seeks to find directions along which the classes are best separated.*）

- 同时考虑类内散布和类间散布

（*Takes into consideration the scatter within-classes but also the scatter between-classes.*）



Slide inspired by N. Vasconcelos

第七讲　线性支撑向量机 (*Linear Support Vector Machine*)

7.1 最大间隔分类面(*Large-Margin Separating Hyperplane*)

7.2 标准的最大间隔问题(*Standard Large-Margin Problem*)

7.3 支撑向量机(*Support Vector Machine*)

7.2 标准的最大间隔问题

样本到分类面的距离

$$\max_{\mathbf{w}} \quad \text{margin}(\boldsymbol{w})$$
$$\text{Subject to} \quad \text{every } y_n \boldsymbol{w}^T \mathbf{x}_n > 0$$
$$\text{margin}(\boldsymbol{w}) = \min_{n=1,\dots,N} \text{distance}(\mathbf{x}_n, \boldsymbol{w})$$

为了便于了解分类器特性，支撑向量机的分析过程中样本向量不做增广

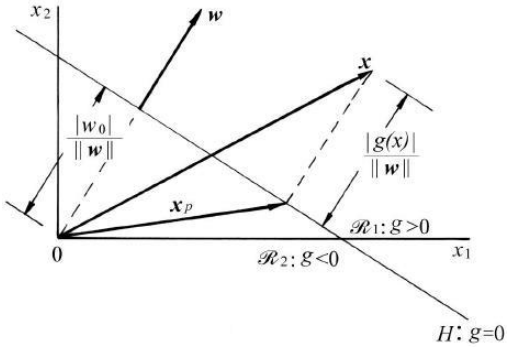
$$\begin{bmatrix} b \\ \mathbf{w} \end{bmatrix} = \begin{bmatrix} w_0 \\ w_1 \\ \vdots \\ w_d \end{bmatrix}; \quad \begin{bmatrix} x_0 = 1 \\ \mathbf{x} \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix}$$

$$h(\mathbf{x}) = \text{sign}(\mathbf{w}^T \mathbf{x} + b)$$

7.2 标准的最大间隔问题

样本到分类面的距离

$$\max_{\mathbf{w}} \quad \text{margin}(\boldsymbol{w})$$
$$\text{Subject to} \quad every\ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$
$$\text{margin}(\boldsymbol{w}) = \min_{n=1,\dots,N} \text{distance}(\mathbf{x}_n, \boldsymbol{w})$$

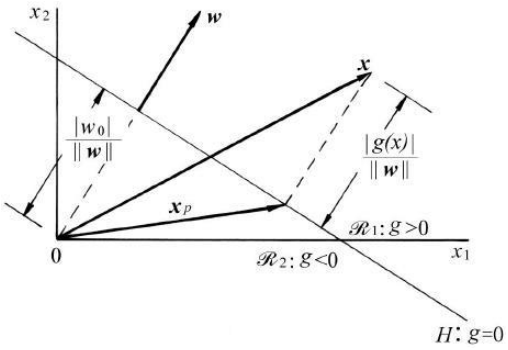


$$g(\mathbf{x}) = \boldsymbol{w}^T\mathbf{x} + w_0$$
$$= \boldsymbol{w}^T\left(\mathbf{x}_p + r\frac{\boldsymbol{w}}{\|\boldsymbol{w}\|}\right) + w_0$$
$$= \boldsymbol{w}^T\,\mathbf{x}_p + w_0 + r\frac{\boldsymbol{w}^T\boldsymbol{w}}{\|\boldsymbol{w}\|}$$
$$= r\|\boldsymbol{w}\|$$

7.2 标准的最大间隔问题

样本到分类面的距离

$$\max_{\mathbf{w}} \quad \text{margin}(\boldsymbol{w})$$
$$\text{Subject to} \quad every\ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$
$$\text{margin}(\boldsymbol{w}) = \min_{n=1,\dots,N} \text{distance}(\mathbf{x}_n, \boldsymbol{w})$$



$$g(\mathbf{x}) = \boldsymbol{w}^T\mathbf{x} + b$$
$$= \boldsymbol{w}^T\left(\mathbf{x}_p + r\frac{\boldsymbol{w}}{\|\boldsymbol{w}\|}\right) + b$$
$$= \boldsymbol{w}^T\,\mathbf{x}_p + b + r\frac{\boldsymbol{w}^T\boldsymbol{w}}{\|\boldsymbol{w}\|}$$
$$= r\|\boldsymbol{w}\|$$

$$|r| = \frac{|g(\mathbf{x})|}{\|\boldsymbol{w}\|} \Rightarrow \text{distance}(\mathbf{x}_n, \boldsymbol{w}) = \frac{1}{\|\boldsymbol{w}\|}\left|\boldsymbol{w}^T\mathbf{x} + b\right|$$

7.2 标准的最大间隔问题

样本到分类面的距离

$$\text{distance}(\mathbf{x}_n, \boldsymbol{w}) = \frac{1}{\|\boldsymbol{w}\|}\left|\boldsymbol{w}^T\mathbf{x} + \boldsymbol{b}\right|$$

$$\because \quad every \ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$

$$\text{distance}(\mathbf{x}_n, \boldsymbol{w}) = \frac{1}{\|\boldsymbol{w}\|} y_n(\boldsymbol{w}^T\mathbf{x}_n + b)$$

$$\max_{\boldsymbol{w}} \quad \text{margin}(\boldsymbol{w})$$

$$Subject\ to \quad every \ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$

$$\text{margin}(\boldsymbol{w}) = \min_{n=1,\dots,N} \text{distance}(\mathbf{x}_n, \boldsymbol{w})$$

$$\max_{\boldsymbol{w}} \quad \text{margin}(\boldsymbol{w})$$

$$Subject\ to \quad every \ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$

$$\text{margin}(\boldsymbol{w}) = \min_{n=1,\dots,N} \frac{1}{\|\boldsymbol{w}\|} y_n(\boldsymbol{w}^T\mathbf{x}_n + b)$$

7.2 标准的最大间隔问题

分类面 ：

$$\boldsymbol{w}^T\mathbf{x}_n + b = 0$$

$$\max_{\boldsymbol{w}} \quad \text{margin}(\boldsymbol{w})$$

$$Subject\ to \quad every \ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$

$$\text{margin}(\boldsymbol{w}) = \min_{n=1,\dots,N} \frac{1}{\|\boldsymbol{w}\|} y_n(\boldsymbol{w}^T\mathbf{x}_n + b)$$

7.2 标准的最大间隔问题

分类面的尺度缩放：

$\boldsymbol{w}^T\mathbf{x}_n + b = 0$

$3\boldsymbol{w}^T\mathbf{x}_n + 3b = 0$

$\min\limits_{n=1,\dots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$

$$\text{margin}(\boldsymbol{w}) = \frac{1}{\|\boldsymbol{w}\|}$$

$$\max_{\boldsymbol{w}} \quad \text{margin}(\boldsymbol{w})$$

$$\textit{Subject to} \quad \textit{every}\ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$

$$\text{margin}(\boldsymbol{w}) = \min_{n=1,\dots,N} \frac{1}{\|\boldsymbol{w}\|} y_n(\boldsymbol{w}^T\mathbf{x}_n + b)$$

$$\max_{\boldsymbol{w}} \quad \frac{1}{\|\boldsymbol{w}\|}$$

$$\textit{Subject to} \quad \textit{every}\ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$

$$\min_{n=1,\dots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

7.2 标准的最大间隔问题

分类面的尺度缩放：

$\boldsymbol{w}^T\mathbf{x}_n + b = 0$

$3\boldsymbol{w}^T\mathbf{x}_n + 3b = 0$

$\min\limits_{n=1,\dots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$

$$\text{margin}(\boldsymbol{w}) = \frac{1}{\|\boldsymbol{w}\|}$$

$$\max_{\boldsymbol{w}} \quad \text{margin}(\boldsymbol{w})$$

$$\textit{Subject to} \quad \textit{every}\ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$

$$\text{margin}(\boldsymbol{w}) = \min_{n=1,\dots,N} \frac{1}{\|\boldsymbol{w}\|} y_n(\boldsymbol{w}^T\mathbf{x}_n + b)$$

$$\max_{\boldsymbol{w}} \quad \frac{1}{\|\boldsymbol{w}\|}$$

$$\textit{Subject to} \quad \textit{every}\ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) > 0$$

$$\min_{n=1,\dots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

人工智能与自动化学院 20

7.2 标准的最大间隔问题

标准的最大间隔问题：

$$\max_{\boldsymbol{w}} \quad \frac{1}{\|\boldsymbol{w}\|}$$

$$Subject\ to \quad \min_{n=1,\dots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

原始约束条件下的值域

$$\min_{n=1,\dots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

7.2 标准的最大间隔问题

标准的最大间隔问题：

$$\max_{\boldsymbol{w}} \quad \frac{1}{\|\boldsymbol{w}\|}$$

$$Subject\ to \quad \min_{n=1,\dots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

条件松弛后的值域

$$y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$$

原始约束条件下的值域

$$\min_{n=1,\dots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

条件松弛后的解仍然在紫色值域

如果$(\boldsymbol{w}^*, b^*)$位于蓝色值域，即对所有样本：

$$y_n(\boldsymbol{w}^{*T}\mathbf{x}_n + b^*) \geq 1.6$$

根据分类面$(\boldsymbol{w}^*, b^*)$取值的尺度不变：

$$y_n\left(\frac{\boldsymbol{w}^{*T}}{1.6}\mathbf{x}_n + \frac{b^*}{1.6}\right) \geq 1$$

$\left(\frac{\boldsymbol{w}^{*T}}{1.6}, \frac{b^*}{1.6}\right)$为最佳解 ➡ 矛盾！！！

7.2 标准的最大间隔问题

标准的最大间隔问题：

条件松弛后的值域

$y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$

原始约束条件下的值域

$\min\limits_{n=1,\ldots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$

条件松弛后的解仍然在紫色值域

$$\max_{w} \quad \frac{1}{\|w\|}$$

$$Subject\ to \quad \min_{n=1,\ldots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

$$\max_{w} \quad \frac{1}{\|w\|}$$

$$Subject\ to \quad y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$$

7.2 标准的最大间隔问题

标准的最大间隔问题：

条件松弛后的值域

$y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$

原始约束条件下的值域

$\min\limits_{n=1,\ldots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$

条件松弛后的解仍然在紫色值域

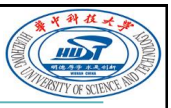
$$\max_{w} \quad \frac{1}{\|w\|}$$

$$Subject\ to \quad \min_{n=1,\ldots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

$$\min_{w} \quad \|w\|$$

$$Subject\ to \quad y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$$

7.2 标准的最大间隔问题



标准的最大间隔问题：

条件松弛后的值域

$y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$

原始约束条件下的值域

$\min\limits_{n=1,\ldots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$

条件松弛后的解仍然在紫色值域

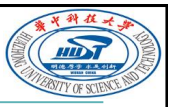
$$\max_{w} \quad \frac{1}{\|w\|}$$

$$Subject\ to \quad \min_{n=1,\ldots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

$$\min_{w} \quad \sqrt{\boldsymbol{w}^T\boldsymbol{w}}$$

$$Subject\ to \quad y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$$

7.2 标准的最大间隔问题



标准的最大间隔问题：

条件松弛后的值域

$y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$

原始约束条件下的值域

$\min\limits_{n=1,\ldots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$

条件松弛后的解仍然在紫色值域

$$\max_{w} \quad \frac{1}{\|w\|}$$

$$Subject\ to \quad \min_{n=1,\ldots,N} y_n(\boldsymbol{w}^T\mathbf{x}_n + b) = 1$$

$$\min_{w} \quad \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$$

$$Subject\ to \quad y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$$

第七讲　线性支撑向量机 (*Linear Support Vector Machine*)

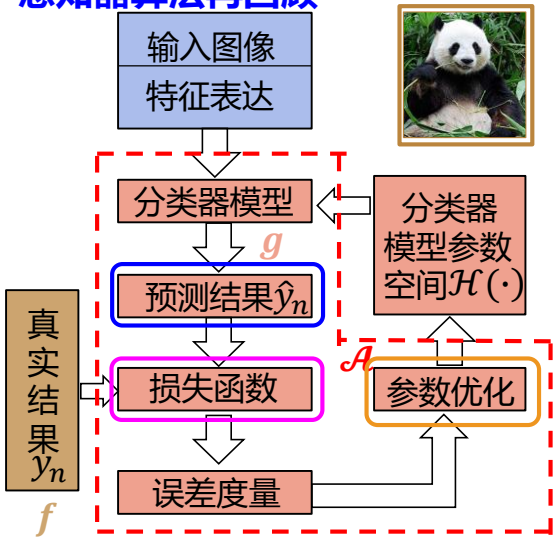
7.1 最大间隔分类面(*Large-Margin Separating Hyperplane*)

7.2 标准的最大间隔问题(*Standard Large-Margin Problem*)

7.3 支撑向量机(*Support Vector Machine*)

7.3 支撑向量机

感知器算法再回顾



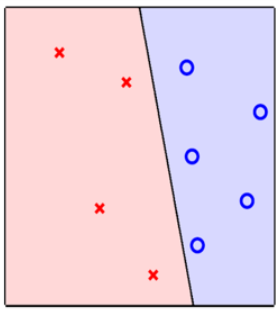
$$\hat{y}_{n(t)} = \text{sign}(\boldsymbol{w}_t^T \mathbf{x}_{n(t)})$$

算法收敛:

$$L_{in} = \sum_{n=1}^{N} [\![y_n \neq \hat{y}_n]\!] = 0$$

$$\boldsymbol{w}_{t+1} = \boldsymbol{w}_t + y_n \mathbf{x}_{n(t)}$$

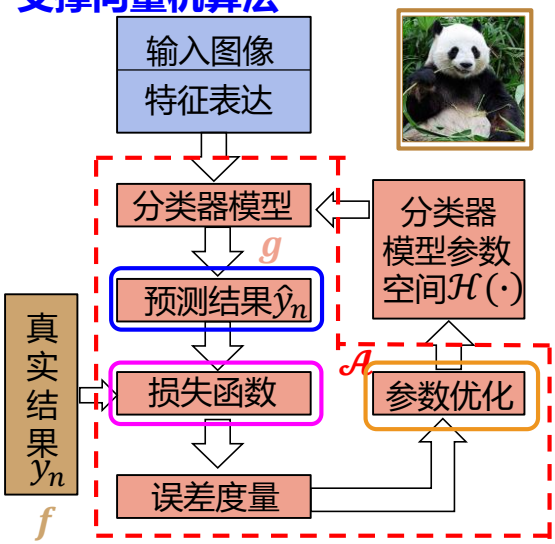
线性可分



- 设置初始分类面(权重)$\boldsymbol{w}_0$
- 如果有样本分错，就修正权重

7.3 支撑向量机

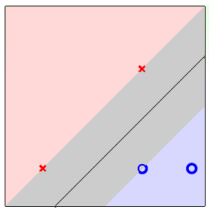
支撑向量机算法



$$\min_{\boldsymbol{w}} \quad \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$$

$$Subject\ to \quad y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$$

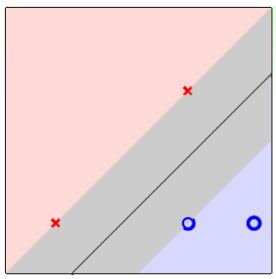
$$\hat{y}_n = \text{sign}(\boldsymbol{w}^T\mathbf{x}_n + b)$$



通过求解目标函数的最优解找到最大间隔作为分类面

7.3 支撑向量机

最大间隔面的求解示例：



$$\mathbf{X} = \begin{bmatrix} 0 & 0 \\ 2 & 2 \\ 2 & 0 \\ 3 & 0 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} -1 \\ -1 \\ +1 \\ +1 \end{bmatrix}$$

$$\min_{\boldsymbol{w}} \quad \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$$

$$Subject\ to \quad y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1, for\ all\ n$$

由约束条件可得：

$$\begin{cases} -b \geq 1 & (1) \\ -2w_1 - 2w_2 - b \geq 1 & (2) \\ 2w_1 + b \geq 1 & (3) \\ 3w_1 + b \geq 1 & (4) \end{cases}$$

对约束条件计算可得：

$$(1) + (3) \Rightarrow w_1 \geq +1$$
$$(2) + (3) \Rightarrow w_2 \leq -1$$

由目标函数$\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$取最小值可得：

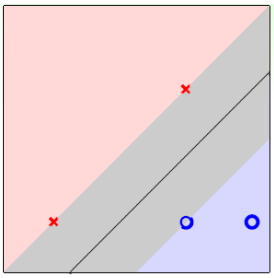
$$w_1 = 1,\ w_2 = -1$$

代入约束条件：

$b \leq -1$，$b \leq -1$，$b \geq -1$，$b \geq -2$；

7.3 支撑向量机

最大间隔面的求解示例：



$$\mathbf{X}=\begin{bmatrix}0&0\\2&2\\2&0\\3&0\end{bmatrix}\quad \mathbf{y}=\begin{bmatrix}-1\\-1\\+1\\+1\end{bmatrix}$$

$$\min_{w}\ \frac{1}{2}w^Tw$$

$$Subject\ to\quad y_n(w^T\mathbf{x}_n+b)\geq 1, for\ all\ n$$

由约束条件可得：

$$\begin{cases} -b\geq 1 & (1)\\ -2w_1-2w_2-b\geq 1 & (2)\\ 2w_1+b\geq 1 & (3)\\ 3w_1+b\geq 1 & (4)\end{cases}$$

对约束条件计算可得：

$$(1)+(3)\Rightarrow w_1\geq +1$$
$$(2)+(3)\Rightarrow w_2\leq -1$$

由目标函数$\frac{1}{2}w^Tw$取最小值可得：

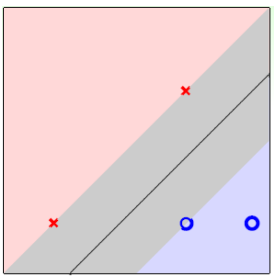
$$w_1=1,\ w_2=-1$$

代入约束条件：

$b\leq -1$，$b\leq -1$，$b\geq -1$，$b\geq -2$；

7.3 支撑向量机

最大间隔面的求解示例：



$$\mathbf{X}=\begin{bmatrix}0&0\\2&2\\2&0\\3&0\end{bmatrix}\quad \mathbf{y}=\begin{bmatrix}-1\\-1\\+1\\+1\end{bmatrix}$$

$$\min_{w}\ \frac{1}{2}w^Tw$$

$$Subject\ to\quad y_n(w^T\mathbf{x}_n+b)\geq 1, for\ all\ n$$

由约束条件可得：

$$\begin{cases} -b\geq 1 & (1)\\ -2w_1-2w_2-b\geq 1 & (2)\\ 2w_1+b\geq 1 & (3)\\ 3w_1+b\geq 1 & (4)\end{cases}$$

对约束条件计算可得：

$$(1)+(3)\Rightarrow w_1\geq +1$$
$$(2)+(3)\Rightarrow w_2\leq -1$$

由目标函数$\frac{1}{2}w^Tw$取最小值可得：

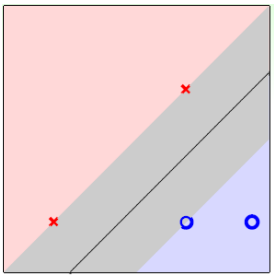
$$w_1=1,\ w_2=-1$$

代入约束条件：$b=-1$

$$\hat{y}_n=\text{sign}(w^T\mathbf{x}_n+b)$$

7.3 支撑向量机

最大间隔面的求解示例：



$$\mathbf{X}=\begin{bmatrix}0&0\\2&2\\2&0\\3&0\end{bmatrix}\quad \mathbf{y}=\begin{bmatrix}-1\\-1\\+1\\+1\end{bmatrix}$$

$$\min_{w}\ \frac{1}{2}w^Tw$$

$$Subject\ to\quad y_n(w^T\mathbf{x}_n+b)\geq 1, for\ all\ n$$

由约束条件可得：

$$\begin{cases} -b\geq 1 & (1)\\ -2w_1-2w_2-b\geq 1 & (2)\\ 2w_1+b\geq 1 & (3)\\ 3w_1+b\geq 1 & (4)\end{cases}$$

对约束条件计算可得：

$$(1)+(3)\Rightarrow w_1\geq +1$$
$$(2)+(3)\Rightarrow w_2\leq -1$$

由目标函数$\frac{1}{2}w^Tw$取最小值可得：

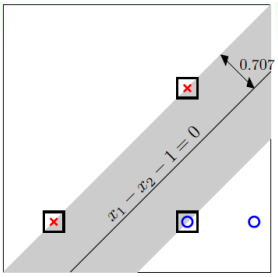
$$w_1=1,\ w_2=-1$$

代入约束条件：$b=-1$

$$\hat{y}=g(\mathbf{x})=\text{sign}(x_1-x_2-1)$$

7.3 支撑向量机

为什么叫支撑向量机？



$$\mathbf{X}=\begin{bmatrix}0&0\\2&2\\2&0\\3&0\end{bmatrix}\quad \mathbf{y}=\begin{bmatrix}-1\\-1\\+1\\+1\end{bmatrix}$$

$$\min_{w}\ \frac{1}{2}w^Tw$$

$$Subject\ to\quad y_n(w^T\mathbf{x}_n+b)\geq 1, for\ all\ n$$

优化得到的解为：

$$w_1=1,\ w_2=-1,\ \ b=-1$$

$$g(\mathbf{x})=\text{sign}(x_1-x_2-1)$$

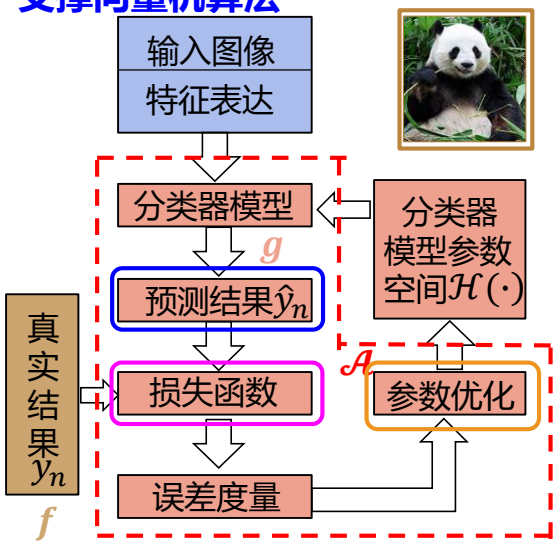
$$\text{margin}(\boldsymbol{w})=\frac{1}{\|\boldsymbol{w}\|}=\frac{1}{\sqrt{2}}$$

- 分类面由边界上的样本确定，其他样本不起作用
- 边界上的样本被称为支撑向量(候选)

支撑向量机(SVM)—Support Vector Machine
----借助支撑向量学到间隔最大分类面

7.3 支撑向量机

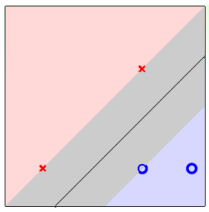
支撑向量机算法



$$\min_{w} \quad \frac{1}{2} w^T w$$

$$Subject\ to \quad y_n(w^T \mathbf{x}_n + b) \geq 1, for\ all\ n$$

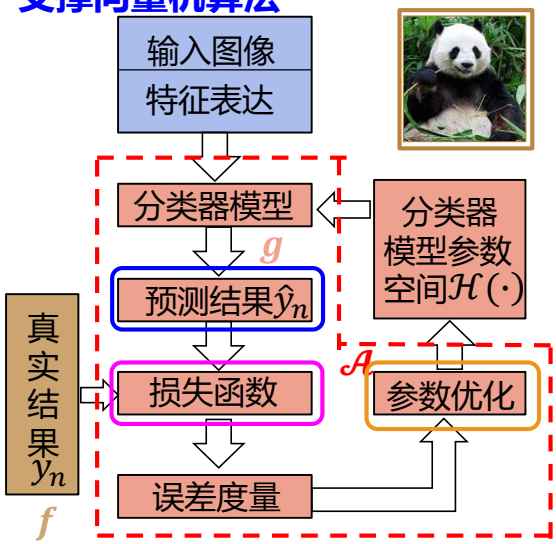
$$\hat{y}_n = \text{sign}(w^T \mathbf{x}_n + b)$$



通过求解目标函数的最优解找到最大间隔作为分类面

7.3 支撑向量机

支撑向量机算法



$$\min_{w} \quad \frac{1}{2} w^T w$$

$$Subject\ to \quad y_n(w^T \mathbf{x}_n + b) \geq 1, for\ all\ n$$

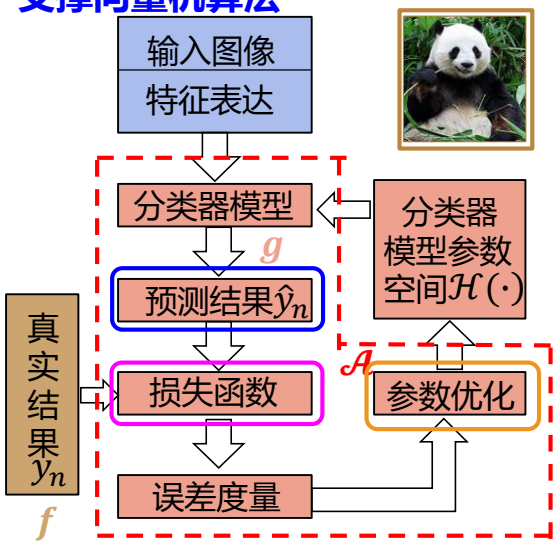
感知器算法的损失函数：

$$L_{in} = \sum_{n=1}^{N} [\![y_n \neq \hat{y}_n]\!] = 0$$

$$\hat{y}_n = \text{sign}(w^T \mathbf{x}_n + b)$$

7.3 支撑向量机

支撑向量机算法



$$\min_{w} \quad \frac{1}{2} w^T w$$

$$Subject\ to \quad y_n(w^T \mathbf{x}_n + b) \geq 1, for\ all\ n$$

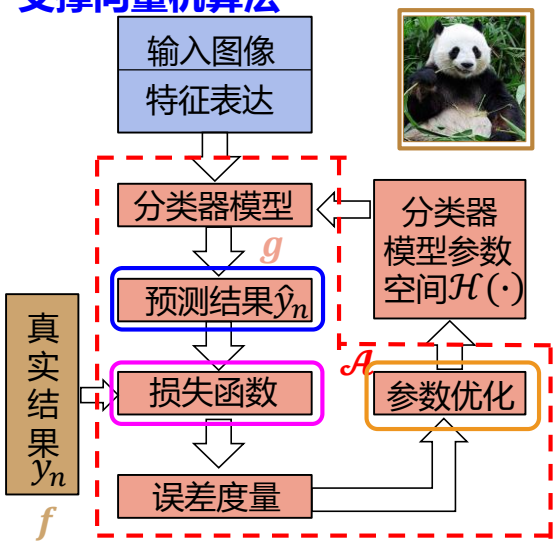
支撑向量机算法的损失函数?

$$L_{SVM} = ?$$

$$\hat{y}_n = \text{sign}(\boldsymbol{w}^T \mathbf{x}_n + b)$$

7.3 支撑向量机

支撑向量机算法



$$y_n(\boldsymbol{w}^T \mathbf{x}_n + b) \geq 1$$

$$y_n s_n \geq 1$$

$$1 - y_n s_n \leq 0$$

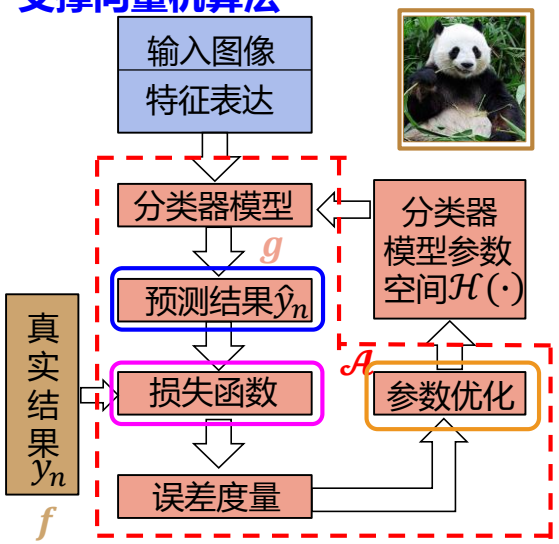
支撑向量机算法的损失函数?

$$L_{SVM} = ?$$

$$\hat{y}_n = \text{sign}(\boldsymbol{w}^T \mathbf{x}_n + b)$$

7.3 支撑向量机

支撑向量机算法



$$y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1$$
$$y_n s_n \geq 1$$
$$1 - y_n s_n \leq 0$$

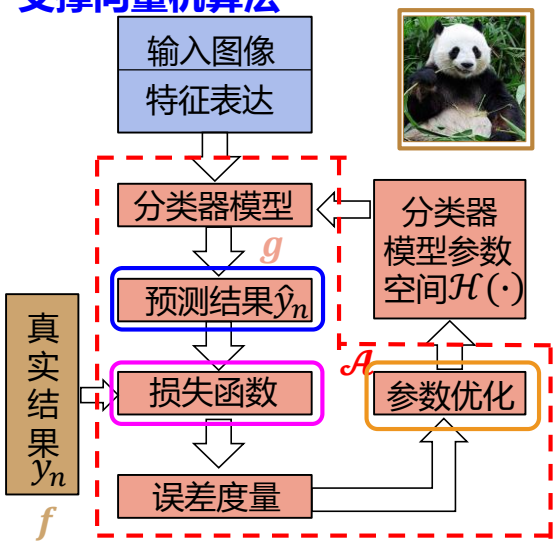
支撑向量机算法的损失函数

$$L_{SVM} = \max(0, 1 - ys)$$ Hinge Loss

$$\hat{y}_n = \text{sign}(\boldsymbol{w}^T\mathbf{x}_n + b)$$

7.3 支撑向量机

支撑向量机算法



$$y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1$$
$$y_n s_n \geq 1$$
$$1 - y_n s_n \leq 0$$

支撑向量机算法的损失函数

$$L_{SVM} = \max(0, 1 - ys)$$ Hinge Loss

$$\frac{\partial L_{SVM}(\boldsymbol{w})}{\partial \boldsymbol{w}} = [\![1 - y_n(\boldsymbol{w}^T\mathbf{x}_n) \geq 0]\!](-y_n\mathbf{x}_n)$$ *(增广后)*

$$\hat{y}_n = \text{sign}(\boldsymbol{w}^T\mathbf{x}_n + b)$$

7.3 支撑向量机

梯度下降法实现支撑向量机

- 初始化权向量$\boldsymbol{w}_0$ **Stochastic Gradient Descent(SGD)**
- $\boldsymbol{for}\ t = 0,1,2,\ldots$（$t$ 代表迭代次数）

① 计算梯度：$\nabla L_{SVM}(\boldsymbol{w}_t) = \frac{1}{B}\sum_{n=1}^{B}[\![1 - y_n(\boldsymbol{w}^T\mathbf{x}_n) \geq 0]\!](-y_n\mathbf{x}_n)$

② 对权向量$\boldsymbol{w}_t$进行更新：$\boldsymbol{w}_{t+1} \leftarrow \boldsymbol{w}_t - \eta\nabla L_{SVM}(\boldsymbol{w}_t)$

…直到对任意$\mathbf{x}_n$满足$1 - y_n(\boldsymbol{w}_{t+1}^T\mathbf{x}_n) < 0$，或者迭代足够多次数

返回最终的$\boldsymbol{w}_{t+1}$作为学到的g

3.3 梯度下降法（引）

训练(Training)



随机梯度下降法(SGD)：

$$\nabla L_{in}(\boldsymbol{w}) = \sum_{n=1}^{B}(\boldsymbol{w}^T\mathbf{x}_n - y_n)\mathbf{x}_n$$

$\boldsymbol{m}_{i,t+1} = \lambda\boldsymbol{m}_{i,t}$ …

$\boldsymbol{w}_{i,t+1} \leftarrow \boldsymbol{w}$ …

不同损失函数在梯度下降时的速度不同

- *问题1：学习率*
- *问题2：梯度为…理解?*
- *问题3：训练样本批量大小的影响?*
- *问题4：损失函数的影响?*

5. 2 逻辑斯蒂回归损失（引）

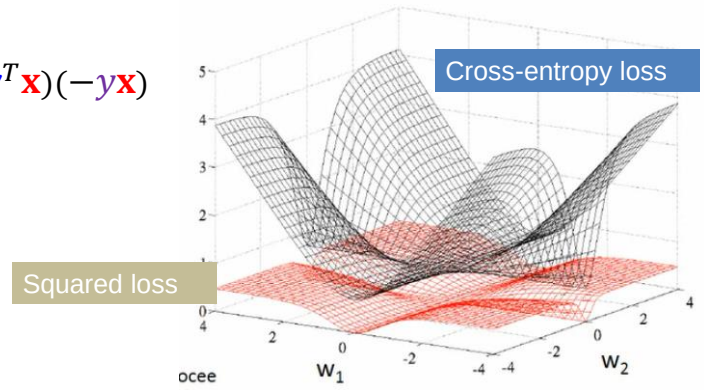
交叉熵损失与平方损失的梯度对比：

平方损失的梯度：

$$\nabla L_{in}(\boldsymbol{w},\mathbf{x},y) = 2(\theta(y\boldsymbol{w}^T\mathbf{x}) - 1)\theta(y\boldsymbol{w}^T\mathbf{x})(1\text{-}\theta(y\boldsymbol{w}^T\mathbf{x}))y\mathbf{x}$$

交叉熵损失的梯度：

$$\nabla L_{in}(\boldsymbol{w},\mathbf{x},y) = \theta(-y\boldsymbol{w}^T\mathbf{x})(-y\mathbf{x})$$



7. 3 支撑向量机

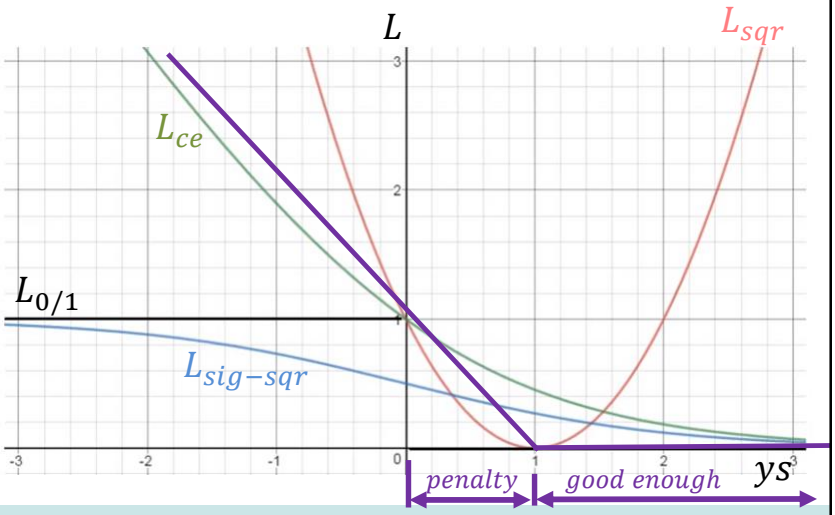
$$L_{0/1} = [\![\hat{y} \neq y]\!]$$

$$L_{sqr} = (ys - 1)^2$$

$$L_{sig-sqr} = (\theta(ys) - 1)^2$$

$$L_{ce} = \ln(1 + \exp(-ys))$$

$$L_{SVM} = \max(0, 1 - ys)$$



7.3 支撑向量机

SVM的一般求解：

$$\min_{w} \quad \frac{1}{2} w^T w$$
$$Subject\ to \quad y_n(w^T \mathbf{x}_n + b) \geq 1, for\ all\ n$$

- 一般情况下，“手工”求解不容易！
- 用梯度下降法？如何处理约束条件？

SVM求解模型的特点：

- (w, b)的目标函数是二次函数，是凸函数！
- (w, b)的约束条件是线性函数！

----二次规划(*quadratic programming*)问题！

二次规划(QP)
有成熟方便的办法求优化解！

7.3 支撑向量机

SVM的一般求解：

最佳的(w, b) =?

$$\min_{w} \quad \frac{1}{2} w^T w$$
$$Subject\ to \quad y_n(w^T \mathbf{x}_n + b) \geq 1 \quad for\ n = 1,2,\dots N$$

二次规划(QP)的求解：

最佳的$\mathbf{u} \leftarrow \mathrm{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$

$$\min_{\mathbf{u}} \quad \frac{1}{2} \mathbf{u}^T \mathbf{Q} \mathbf{u} + \mathbf{p}^T \mathbf{u}$$
$$Subject\ to \quad \mathbf{a}_m^T \mathbf{u} \geq c_m \quad for\ m = 1,2,\dots M$$

$$\mathbf{u} = \begin{bmatrix} b \\ w \end{bmatrix}, \quad \mathbf{Q} = \begin{bmatrix} 0 & \mathbf{0}_d^T \\ \mathbf{0}_d & \mathbf{I}_d \end{bmatrix}, \quad \mathbf{p} = \mathbf{0}_{d+1}$$

$$\mathbf{a}_n^T = y_n [1 \quad \mathbf{x}_n^T], \quad c_n = 1, \quad M = N$$

通过调用二次规划(QP)的求解函数就能得到SVM的最优解

7.3 支撑向量机

利用二次规划(QP)实现支撑向量机

① $\mathbf{Q}=\begin{bmatrix}0 & \mathbf{0}_d^T\\ \mathbf{0}_d & \boldsymbol{I}_d\end{bmatrix}$, $\mathbf{p}=\mathbf{0}_{d+1}$, $\mathbf{a}_n^T=y_n[1 \quad \mathbf{x}_n^T]$, $c_n=1$,

② $\begin{bmatrix}b\\ \boldsymbol{w}\end{bmatrix} \leftarrow \mathrm{QP}(\mathbf{Q},\mathbf{p},\mathbf{A},\mathbf{c})$

③ 返回最终的b和$\boldsymbol{w}$作为学到的g_{SVM}

线性硬间隔SVM算法(*Linear Hard-Margin SVM Algorithm*)

- *Hard-Margin*：没有任何样本会落入到"胖胖的"间隔区域里!
- *Linear*：样本$\mathbf{x}_n$是线性可分的! *如果不*是线性可分？ $\mathbf{z}_n=\boldsymbol{\phi}(\mathbf{x}_n)$

第七讲　线性支撑向量机 (*Linear Support Vector Machine*)

7.1 最大间隔分类面(*Large-Margin Separating Hyperplane*)
直觉上对噪声更为鲁棒

7.2 标准的最大间隔问题(*Standard Large-Margin Problem*)
最小化$\boldsymbol{w}$的模长，使得对所有样本都正确分类

7.3 支撑向量机(*Support Vector Machine*)
利用二次规划QP获得最佳解