人工智能与自动化学院

模 式 识 别

授课教师：杨卫东　胡静

L6-1



第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)

8.1 对偶支撑向量机动机(*Motivation of Dual SVM*)

8.2 对偶支撑向量机的拉格朗日分析(*Lagrange Dual SVM*)

8.3 求解对偶支撑向量机最佳值(*Solving Dual SVM*)

8.4 对偶支撑向量机讨论(*Messages behind Dual SVM*)

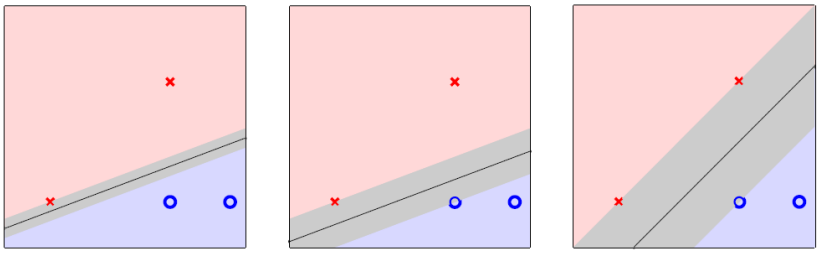
8.5 核函数支撑向量机(*Kernel SVM*)

7.1 最大间隔分类面

“胖胖”的分类面

⇕

最大间隔分类面



所有样本正确分类

⇕

$y_n = \text{sign}(\boldsymbol{w}^T\mathbf{x}_n)$

$$\max_{\mathbf{w}} \ \text{margin}(\mathbf{w})$$

$$\text{subject to} \ \ \text{every } y_n\mathbf{w}^T\mathbf{x}_n > 0$$

$$\text{margin}(\mathbf{w}) = \min_{n=1,\dots,N} \text{distance}(\mathbf{x}_n, \mathbf{w})$$

算法的目的是：如何找到“最大间隔”的分类面(*find largest-margin separating hyperplane*)

8.1 对偶支撑向量机动机

线性支撑向量机模型

最佳的$(\boldsymbol{w}, b)$ =?

$$\min_{\boldsymbol{w}} \ \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$$

$$Subject\ to \ \ y_n(\boldsymbol{w}^T\mathbf{x}_n + b) \geq 1$$

$$for\ n = 1,2,\dots N$$

① $\mathbf{Q} = \begin{bmatrix} 0 & \mathbf{0}_d^T \\ \mathbf{0}_d & \boldsymbol{I}_d \end{bmatrix}$, $\mathbf{p} = \mathbf{0}_{d+1}$,

$\mathbf{a}_n^T = y_n[1 \quad \mathbf{x}_n^T]$, $c_n = 1$,

② $\begin{bmatrix} b \\ \boldsymbol{w} \end{bmatrix} \leftarrow \text{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$

③ 返回最终的b和$\boldsymbol{w}$作为学到的g_{SVM}

二次规划(QP, Quadratic Programming)

利用二次规划(QP)实现支撑向量机

① $\mathbf{Q}=\begin{bmatrix}0 & \mathbf{0}_d^T\\ \mathbf{0}_d & \boldsymbol{I}_d\end{bmatrix}$, $\mathbf{p}=\mathbf{0}_{d+1}$, $\mathbf{a}_n^T=y_n[1 \quad \mathbf{x}_n^T]$, $c_n=1$,

② $\begin{bmatrix}b\\ \boldsymbol{w}\end{bmatrix} \leftarrow \mathrm{QP}(\mathbf{Q},\mathbf{p},\mathbf{A},\mathbf{c})$

③ 返回最终的b和$\boldsymbol{w}$作为学到的g_{SVM}

线性硬间隔SVM算法(*Linear Hard-Margin SVM Algorithm*)

- *Hard-Margin*：没有任何样本会落入到“胖胖的”间隔区域里!
- *Linear*：样本$\mathbf{x}_n$是线性可分的! *如果不*是线性可分？ $\mathbf{z}_n=\boldsymbol{\phi}(\mathbf{x}_n)$

非线性支撑向量机模型

最佳的$(\boldsymbol{w},b)$ =?

$$\min_{\boldsymbol{w}} \quad \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$$

$$Subject\ to \quad y_n(\boldsymbol{w}^T\underbrace{\boldsymbol{z}_n}_{\boldsymbol{\phi}(\mathbf{x}_n)}+b)\geq 1$$

$$for\ n=1,2,\dots N$$

① $\mathbf{Q}=\begin{bmatrix}0 & \mathbf{0}_{\tilde{d}}^T\\ \mathbf{0}_{\tilde{d}} & \boldsymbol{I}_{\tilde{d}}\end{bmatrix}$, $\mathbf{p}=\mathbf{0}_{\tilde{d}+1}$,

$\mathbf{a}_n^T=y_n[1 \quad \mathbf{x}_n^T]$, $c_n=1$,

② $\begin{bmatrix}b\\ \boldsymbol{w}\end{bmatrix} \leftarrow \mathrm{QP}(\mathbf{Q},\mathbf{p},\mathbf{A},\mathbf{c})$

③ 返回最终的b和$\boldsymbol{w}$作为学到的g_{SVM}

如果 $\tilde{d}$ 很大，甚至无穷大，挑战巨大

QP针对$(\tilde{d}+1)$ 个变量和N 个约束条件求解

目的：SVM算法求解可以不依赖于$\tilde{d}$ 吗?

3. 2 线性回归算法

线性回归算法

- 对训练样本集 $\mathcal{D}$ 构造输入特征向量矩阵 $\mathbf{X}$ 和输出向量 Y

$$\mathbf{X} = \begin{bmatrix} -\ -\mathbf{x}_1{}^T\ - \\ -\ -\mathbf{x}_2{}^T\ - \\ \vdots \\ -\ -\mathbf{x}_N{}^T\ - \end{bmatrix}, \qquad Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$

- 计算广义逆：$\mathbf{X}^\dagger = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$
- 计算回归值：$g = \boldsymbol{w}^* = \mathbf{X}^\dagger Y$

$\mathbf{X}$: $N \times (d+1)$

Y: $N \times 1$

$\mathbf{X}^\dagger$: $(d+1) \times N$

$\boldsymbol{w}$: $(d+1) \times 1$

8. 1 对偶支撑向量机动机

将有约束条件下的寻优转变为无约束条件下的寻优问题

$$\min_{\boldsymbol{w}} \ \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$$
$$Subject\ to \quad y_n(\boldsymbol{w}^T\boldsymbol{z}_n + b) \geq 1$$
$$for\ n = 1,2,\dots N$$

用Lagrange乘子 α_n 构造Lagrange函数

$$\mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha}) = \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N}\alpha_n(1 - y_n(\boldsymbol{w}^T\boldsymbol{z}_n + b))$$

约束项隐含在*max*中

$$\text{SVM} \equiv \min_{b,\boldsymbol{w}}\left(\max_{all\ \alpha_n \geq 0} \mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})\right) = \min_{b,\boldsymbol{w}}(\infty\ if\ violating,\ \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}\ if\ feasible) = \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$$

- 任何 "*violating*" $(b,\boldsymbol{w})$: $\max_{all\ \alpha_n \geq 0}\left(\blacksquare + \sum_n \alpha_n(\text{一些正数})\right) \rightarrow \infty$
- 任何 "*feasible*" $(b,\boldsymbol{w})$: $\max_{all\ \alpha_n \geq 0}\left(\blacksquare + \sum_n \alpha_n(\text{所有非正数})\right) = \blacksquare$

4.2 Fisher线性判别分析

二分类问题的Fisher线性判别：

学习最佳投影 $\boldsymbol{w}^*$ 的目标函数：

$$J(\boldsymbol{w}) = \frac{between\ class\ scatter}{within\ class\ scatter}$$

$$\boldsymbol{w}^* = \underset{\boldsymbol{w}}{argmax}\, J(\boldsymbol{w})$$

$$J(\boldsymbol{w}) = \frac{\boldsymbol{w}^T \boldsymbol{S}_B \boldsymbol{w}}{\boldsymbol{w}^T \boldsymbol{S}_w \boldsymbol{w}}$$

最大化目标函数问题转化为：

$$\underset{\boldsymbol{w}}{max}\ \boldsymbol{w}^T \boldsymbol{S}_B \boldsymbol{w} \quad Subject\ to\ \boldsymbol{w}^T \boldsymbol{S}_w \boldsymbol{w} = \boldsymbol{K}$$

利用拉格朗日乘子法(*Lagrange multipliers*)：

$$L(\boldsymbol{w}, \lambda) = \boldsymbol{w}^T \boldsymbol{S}_B \boldsymbol{w} + \lambda(\boldsymbol{K} - \boldsymbol{w}^T \boldsymbol{S}_w \boldsymbol{w})$$

$$= \boldsymbol{w}^T (\boldsymbol{S}_B - \lambda \boldsymbol{S}_w)\boldsymbol{w} + \lambda \boldsymbol{K}$$

$$\nabla L_w(\boldsymbol{w}, \lambda) = \frac{\partial L(\boldsymbol{w}, \lambda)}{\partial \boldsymbol{w}} = \boldsymbol{0}^T$$

$$2(\boldsymbol{S}_B - \lambda \boldsymbol{S}_w)\boldsymbol{w} = \boldsymbol{0} \Rightarrow \boldsymbol{S}_B \boldsymbol{w} = \lambda \boldsymbol{S}_w \boldsymbol{w}$$

拉格朗日乘子法(Lagrange multipliers)

$maximize f(x,y)$ subject to $g(x,y) = 0$

这时我们引入一个拉格朗日乘子λ构造出拉格朗日表达式:

$$\mathcal{L}(x, y, \lambda) = f(x,y) - \lambda \cdot g(x,y)$$

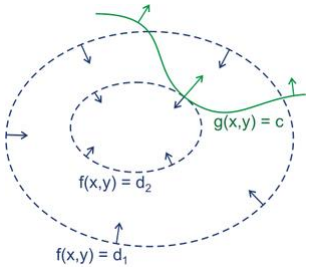
对于有多个限制的表达式，则有:

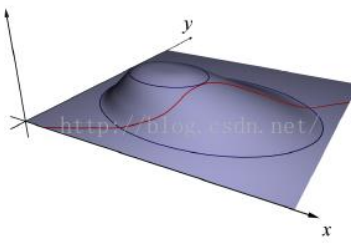
$$\mathcal{L}(x_1, \ldots, x_n, \lambda_1, \ldots, \lambda_M) = f(x_1, \ldots, x_n) - \sum_{k=1}^{M} \lambda_k g_k(x_1, \ldots, x_n)$$

接下来要对拉格朗日表达式求导，令其为0

$$\Delta_{x,y,\lambda} \mathcal{L}(x, y, \lambda) = 0 \iff \Delta_{x,y} f(x,y) = \lambda \Delta_{x,y} g(x,y)\ \&\&\ g(x,y) = 0$$

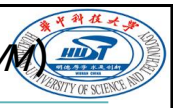
$$\Delta_{x,y} f = (\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y})$$





http://blog.csdn.net/

第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)



8.1 对偶支撑向量机动机(*Motivation of Dual SVM*)

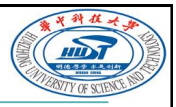
8.2 对偶支撑向量机的拉格朗日分析(*Lagrange Dual SVM*)

8.3 求解对偶支撑向量机最佳值(*Solving Dual SVM*)

8.4 对偶支撑向量机讨论(*Messages behind Dual SVM*)

8.5 核函数支撑向量机(*Kernel SVM*)

8.2 对偶支撑向量机的拉格朗日分析



在所有的$\alpha_n \geq 0$的中挑选任意一个α' $(\because max \geq any)$

$$\min_{b,\boldsymbol{w}}\left(\max_{all\ \alpha_n\geq 0} \mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})\right) \geq \min_{b,\boldsymbol{w}}(\mathcal{L}(b,\boldsymbol{w},\alpha'))$$

如果$\alpha' \geq 0$是上式右边 $\max_{all\ \alpha_n\geq 0} \mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})$中的最佳值 $(\because best\ is\ one\ of\ any)$

$$\min_{b,\boldsymbol{w}}\left(\max_{all\ \alpha_n\geq 0} \mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})\right) \geq \max_{all\ \alpha'_n\geq 0}\left(\min_{b,\boldsymbol{w}}(\mathcal{L}(b,\boldsymbol{w},\alpha'))\right)$$

Primal Problem原问题　*Lagrange Dual Problem*拉格朗日对偶问题

原问题 (求解$b,\boldsymbol{w}$)与拉格朗日对偶问题 (求解α)的关系

8.2 对偶支撑向量机的拉格朗日分析

二次规划(QP)满足强对偶特性

$$\min_{b,\boldsymbol{w}}\left(\max_{all\ \alpha_n\geq 0}\mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})\right)\geq\max_{all\ \alpha_n\geq 0}\left(\min_{b,\boldsymbol{w}}(\mathcal{L}(b,\boldsymbol{w},\alpha))\right)$$

equiv.to original SVM Primal Problem（原问题）

Lagrange Dual Problem（对偶问题）

- “≥”是一种弱对偶关系(weak duality)
- “=”是一种强对偶关系(strong duality)，如果满足：

二次规划(QP)问题 ⇐

- 原问题是**凸函数**
- 原问题存在可行解
- 约束条件为线性的

非线性变换$\boldsymbol{\phi}(\mathbf{x}_n)$

8.2 对偶支撑向量机的拉格朗日分析

二次规划(QP)满足强对偶特性

$$\min_{b,\boldsymbol{w}}\left(\max_{all\ \alpha_n\geq 0}\mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})\right)=\max_{all\ \alpha_n\geq 0}\left(\min_{b,\boldsymbol{w}}(\mathcal{L}(b,\boldsymbol{w},\alpha))\right)$$

equiv.to original SVM Primal Problem

Lagrange Dual Problem

等式两边对原问题求解和对对偶问题求解都能得到最优$(b,\boldsymbol{w},\alpha)$

- “≥”是一种弱对偶关系(weak duality)
- “=”是一种强对偶关系(strong duality)，如果满足：

二次规划(QP)问题 ⇐

- 原问题是**凸函数**
- 原问题存在可行解
- 约束条件为线性的

非线性变换$\boldsymbol{\phi}(\mathbf{x}_n)$

8. 2 对偶支撑向量机的拉格朗日分析

对偶问题求解

$$\max_{all\ \alpha_n \geq 0} \left(\min_{b,\boldsymbol{w}} \underbrace{\left(\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n (1 - y_n(\boldsymbol{w}^T\boldsymbol{z}_n + b)) \right)}_{\mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})} \right)$$

- “括号”内的问题(*inner problem*)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})}{\partial b} = -\sum_{n=1}^{N} \alpha_n y_n = 0$$

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0} \left(\min_{b,\boldsymbol{w}} \left(\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n (1 - y_n(\boldsymbol{w}^T\boldsymbol{z}_n)) - \sum_{n=1}^{N} \alpha_n y_n b \right) \right)$$

8. 2 对偶支撑向量机的拉格朗日分析

对偶问题求解

$$\max_{all\ \alpha_n \geq 0} \left(\min_{b,\boldsymbol{w}} \underbrace{\left(\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n (1 - y_n(\boldsymbol{w}^T\boldsymbol{z}_n + b)) \right)}_{\mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})} \right)$$

- “括号”内的问题(*inner problem*)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b,\boldsymbol{w},\boldsymbol{\alpha})}{\partial b} = -\sum_{n=1}^{N} \alpha_n y_n = 0$$

“括号”内的问题b取最佳解时：

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0} \left(\min_{b,\boldsymbol{w}} \left(\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n (1 - y_n(\boldsymbol{w}^T\boldsymbol{z}_n)) \right) \right)$$

8. 2 对偶支撑向量机的拉格朗日分析

对偶问题求解

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0} \left(\min_{b,\boldsymbol{w}} \left(\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n (1 - y_n(\boldsymbol{w}^T \boldsymbol{z}_n)) \right) \right)$$

- “括号”内的问题(*inner problem*)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b, \boldsymbol{w}, \boldsymbol{\alpha})}{\partial w_i} = w_i - \sum_{n=1}^{N} \alpha_n y_n z_{n,i} = 0 \Rightarrow \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n$$

“括号”内的问题$\boldsymbol{w}$取最佳解时：

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0, \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n} \left(\min_{b,\boldsymbol{w}} \left(\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n - \boldsymbol{w}^T\boldsymbol{w} \right) \right)$$

8. 2 对偶支撑向量机的拉格朗日分析

对偶问题求解

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0} \left(\min_{b,\boldsymbol{w}} \left(\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n (1 - y_n(\boldsymbol{w}^T \boldsymbol{z}_n)) \right) \right)$$

- “括号”内的问题(*inner problem*)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b, \boldsymbol{w}, \boldsymbol{\alpha})}{\partial w_i} = w_i - \sum_{n=1}^{N} \alpha_n y_n z_{n,i} = 0 \Rightarrow \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n$$

“括号”内的问题$\boldsymbol{w}$取最佳解时：

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0, \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n} \left(\min_{b,\boldsymbol{w}} \left(-\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n \right) \right)$$

8. 2 对偶支撑向量机的拉格朗日分析

对偶问题求解

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0} \left(\min_{b,\boldsymbol{w}} \left(\frac{1}{2}\boldsymbol{w}^T\boldsymbol{w} + \sum_{n=1}^{N} \alpha_n (1 - y_n(\boldsymbol{w}^T \boldsymbol{z}_n)) \right) \right)$$

- “括号”内的问题(*inner problem*)是无约束条件的优化问题

$$\frac{\partial \mathcal{L}(b, \boldsymbol{w}, \boldsymbol{\alpha})}{\partial w_i} = w_i - \sum_{n=1}^{N} \alpha_n y_n z_{n,i} = 0 \Rightarrow \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n$$

“括号”内的问题$\boldsymbol{w}$取最佳解时：

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0, \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n \right\|^2 + \sum_{n=1}^{N} \alpha_n \right)$$

8. 2 对偶支撑向量机的拉格朗日分析

KKT条件

$$\max_{all\ \alpha_n \geq 0, \sum_{n=1}^{N} \alpha_n y_n = 0, \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n \right\|^2 + \sum_{n=1}^{N} \alpha_n \right)$$

如果$(b, \boldsymbol{w}, \boldsymbol{\alpha})$是原问题-对偶问题的最佳解(*primal-dual optimal*)：

- 原问题可行解(*primal feasible*)： $y_n(\boldsymbol{w}^T \boldsymbol{z}_n + b) \geq 1$
- 对偶问题可行解(*dual feasible*)： $\alpha_n \geq 0$
- 对偶“括号”内优化解(*dual-inner optimal*)：$\sum_{n=1}^{N} \alpha_n y_n = 0, \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n$
- 原问题“括号”内优化解(*primal-inner optimal*)： $\alpha_n(1 - y_n(\boldsymbol{w}^T \boldsymbol{z}_n + b) = 0$

----称为KKT条件，为优化的充要条件

利用对偶问题求解最佳$\boldsymbol{\alpha}$后，再用KKT条件得到$(b, \boldsymbol{w})$

KKT条件

KKT条件将Lagrange乘子法所处理涉及等式的约束优化问题推广至不等式

1) 是拉格朗日取得可行解的必要条件；

2) 引入乘子βj，去掉不等式，称作松弛互补条件；

3)、4) 初始约束条件；

5) 不等式约束的 Lagrange Multiplier 需满足的条件

$$minf(x), s.t. h_i(x) = 0, i = 1,2,\dots,m; g_j(x) \le 0, j = 1,2,\dots,n$$

$$L(x,\alpha,\beta) = f(x) + \sum_{i=1}^{m} \alpha_i h_i(x) + \sum_{j=1}^{n} \beta_i g_j(x)$$

$$\begin{aligned} \nabla_x L(x,\alpha,\beta) &= 0 && (1)\\ \beta_j g_j(x) &= 0,\ j = 1,2,\dots,n && (2)\\ h_i(x) &= 0,\ i = 1,2,\dots,m && (3)\\ g_j(x) &\le 0,\ j = 1,2,\dots,n && (4)\\ \beta_j &\ge 0,\ j = 1,2,\dots,n && (5) \end{aligned}$$

第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)

8.1 对偶支撑向量机动机(*Motivation of Dual SVM*)

8.2 对偶支撑向量机的拉格朗日分析(*Lagrange Dual SVM*)

8.3 求解对偶支撑向量机最佳值(*Solving Dual SVM*)

8.4 对偶支撑向量机讨论(*Messages behind Dual SVM*)

8.5 核函数支撑向量机(*Kernel SVM*)

8.3 求解对偶支撑向量机最佳值

支撑向量机的对偶问题求解

$$\max_{all\ \alpha_n \geq 0,\ \sum_{n=1}^{N} \alpha_n y_n = 0,\ \boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n} \left(-\frac{1}{2} \left\| \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n \right\|^2 + \sum_{n=1}^{N} \alpha_n \right)$$

标准的硬间隔SVM的对偶问题----求解最佳$\boldsymbol{\alpha}$:

$$\min_{\boldsymbol{\alpha}} \quad \frac{1}{2} \sum_{n=1}^{N} \sum_{m=1}^{N} \alpha_n \alpha_m y_n y_m \boldsymbol{z}_n^T \boldsymbol{z}_m - \sum_{n=1}^{N} \alpha_n$$

$$Subject\ to \quad \sum_{n=1}^{N} \alpha_n y_n = 0$$

$$\alpha_n \geq 0, for\ n = 1,2,\dots,N$$

- $\boldsymbol{\alpha}$的目标函数是二次函数、凸函数！N个变量
- $\boldsymbol{\alpha}$的约束条件是线性函数！$N+1$个约束条件

----二次规划(QP)问题！

QP有成熟方便的办法求优化解！

8.3 求解对偶支撑向量机最佳值

SVM对偶问题的一般求解:

最佳的$\boldsymbol{\alpha}$ =?

$$\min_{\boldsymbol{\alpha}} \quad \frac{1}{2} \sum_{n=1}^{N} \sum_{m=1}^{N} \alpha_n \alpha_m y_n y_m \boldsymbol{z}_n^T \boldsymbol{z}_m - \sum_{n=1}^{N} \alpha_n$$

$$Subject\ to \quad \sum_{n=1}^{N} \alpha_n y_n = 0$$

$$\alpha_n \geq 0, for\ n = 1,2,\dots,N$$

$$\mathbf{u} = [\alpha_1 \quad \cdots \quad \alpha_n \quad \cdots \quad \alpha_N]^T \qquad \mathbf{p} = -\mathbf{1}_N$$

$$\mathbf{Q} = \begin{bmatrix} y_1 y_1 \boldsymbol{z}_1^T \boldsymbol{z}_1 & \cdots & y_1 y_N \boldsymbol{z}_1^T \boldsymbol{z}_N \\ \vdots & y_n y_m \boldsymbol{z}_n^T \boldsymbol{z}_m & \vdots \\ y_N y_1 \boldsymbol{z}_N^T \boldsymbol{z}_1 & \cdots & y_N y_N \boldsymbol{z}_N^T \boldsymbol{z}_N \end{bmatrix}$$

二次规划(QP)的求解:

最佳的$\mathbf{u} \leftarrow \mathrm{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$

$$\min_{\mathbf{u}} \quad \frac{1}{2} \mathbf{u}^T \mathbf{Q} \mathbf{u} + \mathbf{p}^T \mathbf{u}$$

$$Subject\ to \quad \mathbf{a}_m^T \mathbf{u} \geq c_m \quad for\ m = 1,2,\dots M$$

$$\mathbf{a}_{\geq}^T = [y_1 \quad \cdots \quad y_n \quad \cdots \quad y_N], \qquad c_{\geq} = 0$$

$$\mathbf{a}_{\leq}^T = [-y_1 \quad \cdots \quad -y_n \quad \cdots \quad -y_N], \qquad c_{\leq} = 0$$

$$\mathbf{a}_1^T = [1 \quad \cdots \quad 0 \quad \cdots \quad 0],$$

$$\mathbf{a}_n^T = [0 \quad \cdots \quad 1 \quad \cdots \quad 0], \quad c_n = 0, \quad M = N$$

$$\mathbf{a}_N^T = [0 \quad \cdots \quad 0 \quad \cdots \quad 1],$$

8.3 求解对偶支撑向量机最佳值

利用二次规划(QP)实现支撑向量机对偶问题求解

① $\mathbf{Q}=\begin{bmatrix} y_1y_1\mathbf{z}_1^T\mathbf{z}_1 & \cdots & y_1y_N\mathbf{z}_1^T\mathbf{z}_N \\ \vdots & y_ny_m\mathbf{z}_n^T\mathbf{z}_m & \vdots \\ y_Ny_1\mathbf{z}_N^T\mathbf{z}_1 & \cdots & y_Ny_N\mathbf{z}_N^T\mathbf{z}_N \end{bmatrix}$, $\mathbf{p}=-1_N$,

$\mathbf{a}_n^T=[0 \quad \cdots \quad 1 \quad \cdots \quad 0]$, $c_n=0$,

$\mathbf{a}_{\geq}^T=[y_1 \quad \cdots \quad y_n \quad \cdots \quad y_N]$, $c_{\geq}=0$,

$\mathbf{a}_{\leq}^T=[-y_1 \quad \cdots \quad -y_n \quad \cdots \quad -y_N]$, $c_{\leq}=0$,

② $[\alpha_1 \quad \cdots \quad \alpha_n \quad \cdots \quad \alpha_N]^T \leftarrow \mathrm{QP}(\mathbf{Q},\mathbf{p},\mathbf{A},\mathbf{c})$

③ 返回最终的$\boldsymbol{\alpha}$

8.3 求解对偶支撑向量机最佳值

求解最佳的$(b,\boldsymbol{w})$

如果$(b,\boldsymbol{w},\boldsymbol{\alpha})$是原问题-对偶问题的最佳解(*primal-dual optimal*):

- 原问题可行解(*primal feasible*): $y_n(\boldsymbol{w}^T\mathbf{z}_n+b)\geq 1$
- 对偶问题可行解(*dual feasible*): $\alpha_n\geq 0$
- 对偶"括号"内优化解(*dual-inner optimal*): $\sum_{n=1}^{N}\alpha_n y_n=0$, $\boldsymbol{w}=\sum_{n=1}^{N}\alpha_n y_n\mathbf{z}_n$
- 原问题"括号"内优化解(*primal-inner optimal*): $\alpha_n(1-y_n(\boldsymbol{w}^T\mathbf{z}_n+b))=0$

----称为KKT条件，为优化的充要条件

挑选任意一个 $\alpha_n>0$ 的样本， $b=y_n-\boldsymbol{w}^T\mathbf{z}_n$ $\alpha_n>0$ 的样本是支撑向量

第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)

8.1 对偶支撑向量机动机(*Motivation of Dual SVM*)

8.2 对偶支撑向量机的拉格朗日分析(*Lagrange Dual SVM*)

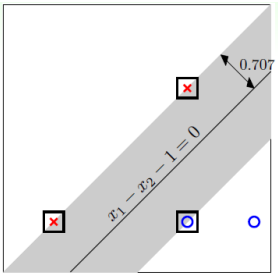
8.3 求解对偶支撑向量机最佳值(*Solving Dual SVM*)

8.4 对偶支撑向量机讨论(*Messages behind Dual SVM*)

8.5 核函数支撑向量机(*Kernel SVM*)

7.3 支撑向量机

为什么叫支撑向量机?



$$\mathbf{X} = \begin{bmatrix} 0 & 0 \\ 2 & 2 \\ 2 & 0 \\ 3 & 0 \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} -1 \\ -1 \\ +1 \\ +1 \end{bmatrix}$$

$$\min_{w} \quad \frac{1}{2} w^T w$$

$$\text{Subject to} \quad y_n(w^T \mathbf{x}_n + b) \geq 1, \text{for all } n$$

优化得到的解为:

$w_1 = 1,\ w_2 = -1,\ b = -1$

$g(\mathbf{x}) = \text{sign}(x_1 - x_2 - 1)$

$$\text{margin}(\boldsymbol{w}) = \frac{1}{\|\boldsymbol{w}\|} = \frac{1}{\sqrt{2}}$$

- 分类面由边界上的样本确定，其他样本不起作用
- 边界上的样本被称为支撑向量(候选)

支撑向量机(SVM)—Support Vector Machine
----借助支撑向量学到间隔最大分类面

8.4 对偶支撑向量机讨论

SVM原问题

- 分类面由边界上的样本确定，其他样本不起作用
- 边界上的样本被称为支撑向量(候选)

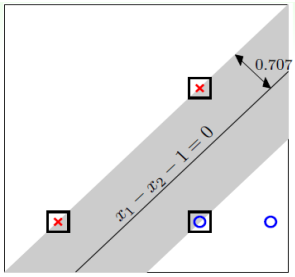
SVM对偶问题

- $\alpha_n > 0$ 的样本落在分类面的边界上
- $\alpha_n > 0$ 的样本$(\boldsymbol{z}_n, y_n)$被称为支撑向量(~~候选~~)

$SV(\alpha_n > 0\text{的样本}) \subseteq SV(\text{边界上的样本})$

求解$\boldsymbol{w}$时，只需要支撑向量: $\boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n = \sum_{\text{SV}} \alpha_n y_n \boldsymbol{z}_n$

求解b时，只需要任一个支撑向量$(\boldsymbol{z}_n, y_n)$： $b = y_n - \boldsymbol{w}^T \boldsymbol{z}_n$



SVM
----利用对偶问题的最佳解确定支撑向量，从而找到间隔最大的分类面

8.4 对偶支撑向量机讨论

SVM:

$$\boldsymbol{w}_{SVM} = \sum_{n=1}^{N} \alpha_n (y_n \boldsymbol{z}_n)$$

α_n由对偶问题的解确定

PLA:

$$\boldsymbol{w}_{PLA} = \sum_{n=1}^{N} \beta_n (y_n \boldsymbol{z}_n)$$

β_n由分错的样本确定

$\boldsymbol{w}$ 是 $y_n \boldsymbol{z}_n$ 的线性组合

$\boldsymbol{w}$ 被数据 $y_n \boldsymbol{z}_n$ 所表达

$\boldsymbol{w}$ 体现出“模式”

SVM： 仅通过SV表达$\boldsymbol{w}$



8.4 对偶支撑向量机讨论

SVM的原问题求解：

$$\min_{\boldsymbol{w}} \quad \frac{1}{2}\boldsymbol{w}^T\boldsymbol{w}$$

$$Subject\ to \quad y_n(\boldsymbol{w}^T\boldsymbol{z}_n + b) \geq 1$$

$$for\ n = 1,2,\dots N$$

- $(\tilde{d}+1)$ 个变量和N 个约束条件
- 求解最佳$(b,\boldsymbol{w})$

SVM的对偶问题求解：

$$\min_{\boldsymbol{\alpha}} \quad \frac{1}{2}\sum_{n=1}^{N}\sum_{m=1}^{N}\alpha_n\alpha_m y_n y_m \mathbf{z}_n^T\mathbf{z}_m - \sum_{n=1}^{N}\alpha_n$$

$$Subject\ to \quad \sum_{n=1}^{N}\alpha_n y_n = 0$$

$$\alpha_n \geq 0, for\ n = 1,2,\dots,N$$

- N 个变量和 $N+1$ 个约束条件
- 求解最佳$\boldsymbol{\alpha}$，确定支撑向量

两种方法都能得到最佳解$(b,\boldsymbol{w})$获得最大间隔分类面$g_{SVM} = \text{sign}(\boldsymbol{w}^T\boldsymbol{\phi}(\mathbf{x}_n) + b)$

第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)

8.1 对偶支撑向量机动机(*Motivation of Dual SVM*)

8.2 对偶支撑向量机的拉格朗日分析(*Lagrange Dual SVM*)

8.3 求解对偶支撑向量机最佳值(*Solving Dual SVM*)

8.4 对偶支撑向量机讨论(*Messages behind Dual SVM*)

8.5 核函数支撑向量机(*Kernel SVM*)

8.5 核函数支撑向量机

研究对偶SVM的动机是**不想依赖**$\tilde{d}$

$$\min_{\alpha} \quad \frac{1}{2}\sum_{n=1}^{N}\sum_{m=1}^{N}\alpha_n\alpha_m y_n y_m \mathbf{z}_n^T\mathbf{z}_m - \sum_{n=1}^{N}\alpha_n$$

$$Subject\ to \quad \sum_{n=1}^{N}\alpha_n y_n = 0$$

$$\alpha_n \geq 0, for\ n = 1,2,\dots,N$$

8.5 核函数支撑向量机

研究对偶SVM的动机是**不想依赖**$\tilde{d}$

$$\min_{\alpha} \quad \frac{1}{2}\boldsymbol{\alpha}^T\mathbf{Q}\boldsymbol{\alpha} - \mathbf{1}^T\boldsymbol{\alpha}$$

$$Subject\ to \quad \mathbf{y}^T\boldsymbol{\alpha} = 0$$

$$\alpha_n \geq 0, for\ n = 1,2,\dots,N$$

$$\mathbf{Q} = \begin{bmatrix} y_1y_1\mathbf{z}_1^T\mathbf{z}_1 & \cdots & y_1y_N\mathbf{z}_1^T\mathbf{z}_N \\ \vdots & y_ny_m\mathbf{z}_n^T\mathbf{z}_m & \vdots \\ y_Ny_1\mathbf{z}_N^T\mathbf{z}_1 & \cdots & y_Ny_N\mathbf{z}_N^T\mathbf{z}_N \end{bmatrix}$$

对偶SVM真的不依赖于$\tilde{d}$?

- N 个变量和 $N+1$ 个约束条件
- 对偶问题的$\mathbf{Q}$ 是个稠密矩阵
- 每个元素$q_{n,m} = y_ny_m\mathbf{z}_n^T\mathbf{z}_m$都要做**内积运算**，计算代价$O(\tilde{d})$

能提高 $\mathbf{z}_n^T\mathbf{z}_m = \Phi(\mathbf{x}_n)^T\Phi(\mathbf{x}_m)$ 计算效率吗?

8.5 核函数支撑向量机

二次多项式$\boldsymbol{\Phi}_2(\mathbf{x})$的快速内积计算

$$\boldsymbol{\Phi}_2(\mathbf{x}) = (1, x_1, x_2, \dots, x_d, x_1^2, x_1x_2, \dots, x_1x_d, x_2x_1, x_2^2, \dots, x_2x_d, x_dx_1, x_dx_2, \dots, x_d^2)$$

$$\begin{aligned}\boldsymbol{\Phi}_2^T(\mathbf{x})\boldsymbol{\Phi}_2(\mathbf{x}') &= 1 + \sum_{i=1}^{d} x_i x_i' + \sum_{i=1}^{d}\sum_{j=1}^{d} x_i x_j x_i' x_j' \\ &= 1 + \sum_{i=1}^{d} x_i x_i' + \sum_{i=1}^{d} x_i x_i' \sum_{j=1}^{d} x_j x_j' \\ &= 1 + \mathbf{x}^T\mathbf{x}' + (\mathbf{x}^T\mathbf{x}')(\mathbf{x}^T\mathbf{x}')\end{aligned}$$

$(\mathbf{x}^T\mathbf{x}')$

计算复杂度从$O(\tilde{d})$下降到$O(d)$

8.5 核函数支撑向量机

核函数： Φ变换+内积计算 ⟹ $K_{\boldsymbol{\Phi}}(\mathbf{x}, \mathbf{x}') = \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x})\boldsymbol{\Phi}(\mathbf{x}')$

$$K_{\boldsymbol{\Phi}_2}(\mathbf{x}, \mathbf{x}') = \boldsymbol{\Phi}_2^T(\mathbf{x})\boldsymbol{\Phi}_2(\mathbf{x}') = 1 + \mathbf{x}^T\mathbf{x}' + (\mathbf{x}^T\mathbf{x}')(\mathbf{x}^T\mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T\mathbf{z}_m = y_n y_m \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x}_n)\boldsymbol{\Phi}(\mathbf{x}_m) = y_n y_m K_{\boldsymbol{\Phi}}(\mathbf{x}_n, \mathbf{x}_m)$$

$$\boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \mathbf{z}_n = \sum_{\text{SV}} \alpha_n y_n \mathbf{z}_n$$

支撑SV$(\mathbf{z}_m, y_m)$： $b = y_m - \boldsymbol{w}^T\mathbf{z}_m = y_m - (\sum_{\text{SV}} \alpha_n y_n \mathbf{z}_n)^T\mathbf{z}_m$

输入测试样本 $\mathbf{x}$： $g_{SVM} = \text{sign}(\boldsymbol{w}^T\boldsymbol{\Phi}(\mathbf{x}) + b)$

8.5 核函数支撑向量机

核函数： Φ变换+内积计算 ⟹ $K_{\boldsymbol{\Phi}}(\mathbf{x},\mathbf{x}') = \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x})\boldsymbol{\Phi}(\mathbf{x}')$

$$K_{\boldsymbol{\Phi}_2}(\mathbf{x},\mathbf{x}') = \boldsymbol{\Phi}_2^T(\mathbf{x})\boldsymbol{\Phi}_2(\mathbf{x}') = 1 + \mathbf{x}^T\mathbf{x}' + (\mathbf{x}^T\mathbf{x}')(\mathbf{x}^T\mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x}_n)\boldsymbol{\Phi}(\mathbf{x}_m) = y_n y_m K_{\boldsymbol{\Phi}}(\mathbf{x}_n,\mathbf{x}_m)$$

$$\boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n = \sum_{\mathrm{SV}} \alpha_n y_n \boldsymbol{z}_n$$

支撑SV$(\boldsymbol{z}_m, y_m)$： $b = y_m - \boldsymbol{w}^T\boldsymbol{z}_m = y_m - \sum_{\mathrm{SV}} \alpha_n y_n \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x}_n)\,\boldsymbol{\Phi}(\mathbf{x}_m)$

输入测试样本 x： $g_{SVM} = \mathrm{sign}(\boldsymbol{w}^T\boldsymbol{\Phi}(\mathbf{x}) + b)$

8.5 核函数支撑向量机

核函数： Φ变换+内积计算 ⟹ $K_{\boldsymbol{\Phi}}(\mathbf{x},\mathbf{x}') = \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x})\boldsymbol{\Phi}(\mathbf{x}')$

$$K_{\boldsymbol{\Phi}_2}(\mathbf{x},\mathbf{x}') = \boldsymbol{\Phi}_2^T(\mathbf{x})\boldsymbol{\Phi}_2(\mathbf{x}') = 1 + \mathbf{x}^T\mathbf{x}' + (\mathbf{x}^T\mathbf{x}')(\mathbf{x}^T\mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x}_n)\boldsymbol{\Phi}(\mathbf{x}_m) = y_n y_m K_{\boldsymbol{\Phi}}(\mathbf{x}_n,\mathbf{x}_m)$$

$$\boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n = \sum_{\mathrm{SV}} \alpha_n y_n \boldsymbol{z}_n$$

支撑SV$(\boldsymbol{z}_m, y_m)$： $b = y_m - \boldsymbol{w}^T\boldsymbol{z}_m = y_m - \sum_{\mathrm{SV}} \alpha_n y_n K_{\boldsymbol{\Phi}}(\mathbf{x}_n,\mathbf{x}_m)$

输入测试样本 x： $g_{SVM} = \mathrm{sign}(\boldsymbol{w}^T\boldsymbol{\Phi}(\mathbf{x}) + b) = sign((\sum_{\mathrm{SV}} \alpha_n y_n \boldsymbol{z}_n)^T\boldsymbol{\Phi}(\mathbf{x}) + b)$

8.5 核函数支撑向量机

核函数： Φ变换+内积计算 ⟹ $K_{\boldsymbol{\Phi}}(\mathbf{x},\mathbf{x}') = \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x})\boldsymbol{\Phi}(\mathbf{x}')$

$$K_{\boldsymbol{\Phi}_2}(\mathbf{x},\mathbf{x}') = \boldsymbol{\Phi}_2^T(\mathbf{x})\boldsymbol{\Phi}_2(\mathbf{x}') = 1 + \mathbf{x}^T\mathbf{x}' + (\mathbf{x}^T\mathbf{x}')(\mathbf{x}^T\mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x}_n)\boldsymbol{\Phi}(\mathbf{x}_m) = y_n y_m K_{\boldsymbol{\Phi}}(\mathbf{x}_n,\mathbf{x}_m)$$

$$\boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n = \sum_{\mathrm{SV}} \alpha_n y_n \boldsymbol{z}_n$$

支撑SV$(\boldsymbol{z}_m, y_m)$： $b = y_m - \boldsymbol{w}^T\boldsymbol{z}_m = y_m - \sum_{\mathrm{SV}} \alpha_n y_n K_{\boldsymbol{\Phi}}(\mathbf{x}_n,\mathbf{x}_m)$

输入测试样本 $\mathbf{x}$： $g_{SVM} = \mathrm{sign}(\boldsymbol{w}^T\boldsymbol{\Phi}(\mathbf{x}) + b) = sign(\sum_{\mathrm{SV}} \alpha_n y_n \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x}_n)\,\boldsymbol{\Phi}(\mathbf{x}) + b)$

8.5 核函数支撑向量机

核函数： Φ变换+内积计算 ⟹ $K_{\boldsymbol{\Phi}}(\mathbf{x},\mathbf{x}') = \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x})\boldsymbol{\Phi}(\mathbf{x}')$

$$K_{\boldsymbol{\Phi}_2}(\mathbf{x},\mathbf{x}') = \boldsymbol{\Phi}_2^T(\mathbf{x})\boldsymbol{\Phi}_2(\mathbf{x}') = 1 + \mathbf{x}^T\mathbf{x}' + (\mathbf{x}^T\mathbf{x}')(\mathbf{x}^T\mathbf{x}')$$

$$q_{n,m} = y_n y_m \mathbf{z}_n^T \mathbf{z}_m = y_n y_m \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x}_n)\boldsymbol{\Phi}(\mathbf{x}_m) = y_n y_m K_{\boldsymbol{\Phi}}(\mathbf{x}_n,\mathbf{x}_m)$$

$$\boldsymbol{w} = \sum_{n=1}^{N} \alpha_n y_n \boldsymbol{z}_n = \sum_{\mathrm{SV}} \alpha_n y_n \boldsymbol{z}_n$$

支撑SV$(\boldsymbol{z}_m, y_m)$： $b = y_m - \boldsymbol{w}^T\boldsymbol{z}_m = y_m - \sum_{\mathrm{SV}} \alpha_n y_n K_{\boldsymbol{\Phi}}(\mathbf{x}_n,\mathbf{x}_m)$

输入测试样本 $\mathbf{x}$： $g_{SVM} = \mathrm{sign}(\boldsymbol{w}^T\boldsymbol{\Phi}(\mathbf{x}) + b) = sign(\sum_{\mathrm{SV}} \alpha_n y_n \boldsymbol{\Phi}^{\boldsymbol{T}}(\mathbf{x}_n)\,\boldsymbol{\Phi}(\mathbf{x}) + b)$

利用核函数，将计算复杂度从$O(\tilde{d})$下降到$O(d)$避免依赖$\tilde{d}$

8.5 核函数支撑向量机

利用二次规划(QP)实现核函数支撑向量机求解

① $q_{n,m} = y_n y_m K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m)$，$\mathbf{p} = -1_N$，由约束条件得到$(\mathbf{A}, \mathbf{c})$

② $\alpha \leftarrow \mathrm{QP}(\mathbf{Q}, \mathbf{p}, \mathbf{A}, \mathbf{c})$

③ 任选一支撑SV$(\mathbf{x}_m, y_m)$：$b \leftarrow (y_m - \sum_{\mathrm{SV}} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}_m))$

④ 对于测试样本 $\mathbf{x}$：$g_{SVM} = sign(\sum_{\mathrm{SV}} \alpha_n y_n K_{\Phi}(\mathbf{x}_n, \mathbf{x}) + b)$

- 步骤①的时间复杂度：$O(N^2) \cdot (kernel\ evaluation)$
- 步骤②的开销　　：N个变量，$N+1$个约束
- 步骤③和④的复杂度：$O(\#\mathrm{SV}) \cdot (kernel\ evaluation)$

8.5 核函数支撑向量机

二次多项式核函数的一般表达式

$\boldsymbol{\Phi}_2(\mathbf{x})$	$\boldsymbol{K}_2(\mathbf{x}, \mathbf{x}')$
$(1, x_1, \ldots, x_d, x_1^2, x_1x_2, \ldots, x_d^2)$	$1 + \mathbf{x}^T\mathbf{x}' + (\mathbf{x}^T\mathbf{x}')^2$
$(1, \sqrt{2}x_1, \ldots, \sqrt{2}x_d, x_1^2, x_1x_2, \ldots, x_d^2)$	$1 + 2\mathbf{x}^T\mathbf{x}' + (\mathbf{x}^T\mathbf{x}')^2$
$(1, \sqrt{2\gamma}x_1, \ldots, \sqrt{2\gamma}x_d, x_1^2, x_1x_2, \ldots, x_d^2)$	$1 + 2\gamma\mathbf{x}^T\mathbf{x}' + \gamma^2(\mathbf{x}^T\mathbf{x}')^2$

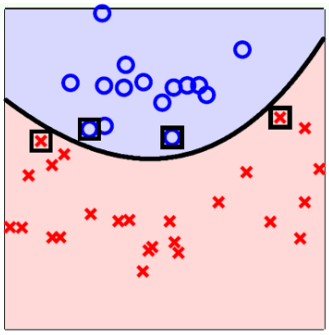
$$\boldsymbol{K}_2(\mathbf{x}, \mathbf{x}') = (1 + \gamma\mathbf{x}^T\mathbf{x}')^2 \qquad \gamma > 0$$

不同的二次多项式变换：

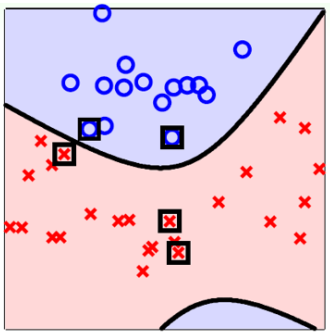
- 升维次数相同
- 内积结果不同 ➡ 分类面不同

8.5 核函数支撑向量机

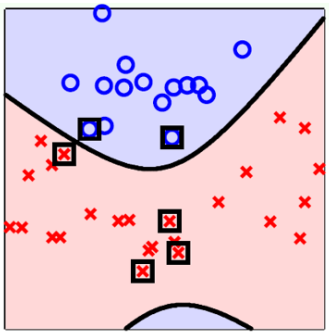
二次多项式核函数的一般表达式



$(1+0.001\mathbf{x}^T\mathbf{x}')^2$



$1+\mathbf{x}^T\mathbf{x}'+(\mathbf{x}^T\mathbf{x}')^2$



$(1+1000\mathbf{x}^T\mathbf{x}')^2$

- 核函数不同 ⟹ 支撑向量(*SV*s)不同，分类面(g_{SVM})不同
- 核函数变化 ⟹ Margin也会变化

8.5 核函数支撑向量机

多项式核函数的一般表达式

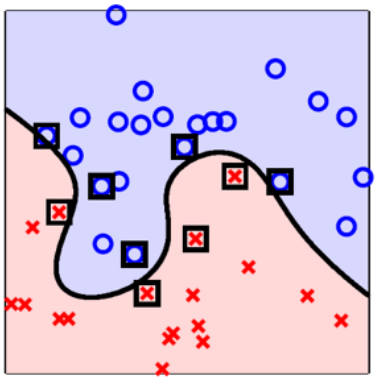
$$\boldsymbol{K_2}(\mathbf{x},\mathbf{x}')=(\zeta+\gamma\mathbf{x}^T\mathbf{x}')^{\boldsymbol{2}} \qquad \gamma>0,\zeta\geq 0$$

$$\boldsymbol{K_3}(\mathbf{x},\mathbf{x}')=(\zeta+\gamma\mathbf{x}^T\mathbf{x}')^{\boldsymbol{3}} \qquad \gamma>0,\zeta\geq 0$$

$$\vdots$$

$$\boldsymbol{K_Q}(\mathbf{x},\mathbf{x}')=(\zeta+\gamma\mathbf{x}^T\mathbf{x}')^{\boldsymbol{Q}} \qquad \gamma>0,\zeta\geq 0$$

- Q、γ、ζ 确定了多项式核函数的形式
- 利用核函数可不依赖于$\tilde{d}$ 获得大间隔分类面



*Margin*为1的10次多项式

SVM + Polynomial Kernel = Polynomial SVM

8.5 核函数支撑向量机

核函数能实现无穷维变换?

当$\boldsymbol{\Phi}(\mathbf{x})$为无穷维变换时，借助核函数$\boldsymbol{K}(\mathbf{x},\mathbf{x}')$技巧仍可进行有效计算

为简单起见，考虑一维变量，即：$\mathbf{x}=(x)$

$$\boldsymbol{K}(x,x') = \exp(-(x-x')^2) = \exp(-(x)^2)\exp(-(x')^2)\exp(2xx')$$

$$= \exp(-(x)^2)\exp(-(x')^2)\left(\sum_{i=0}^{\infty}\frac{(2xx')^i}{i!}\right)$$

$$= \sum_{i=0}^{\infty}\left(\exp(-(x)^2)\exp(-(x')^2)\sqrt{\frac{2^i}{i!}}\sqrt{\frac{2^i}{i!}}(x)^i(x')^i\right)$$

$$\boldsymbol{\Phi}(x) = \exp(-(x)^2)\cdot\left(1,\sqrt{\frac{2^1}{1!}}x,\sqrt{\frac{2^2}{2!}}x^2,\sqrt{\frac{2^3}{3!}}x^3,\dots,\dots\right)$$

8.5 核函数支撑向量机

核函数能实现无穷维变换?

当$\boldsymbol{\Phi}(\mathbf{x})$为无穷维变换时，借助核函数$\boldsymbol{K}(\mathbf{x},\mathbf{x}')$技巧仍可进行有效计算

为简单起见，考虑一维变量，即：$\mathbf{x}=(x)$

$$\boldsymbol{K}(x,x') = \boldsymbol{\Phi}(x)^T\boldsymbol{\Phi}(x') = \exp(-(x-x')^2) = \exp(-(x)^2)\exp(-(x')^2)\exp(2xx')$$

$$= \exp(-(x)^2)\exp(-(x')^2)\left(\sum_{i=0}^{\infty}\frac{(2xx')^i}{i!}\right)$$

$$= \sum_{i=0}^{\infty}\left(\exp(-(x)^2)\exp(-(x')^2)\sqrt{\frac{2^i}{i!}}\sqrt{\frac{2^i}{i!}}(x)^i(x')^i\right)$$

$$\boldsymbol{\Phi}(x) = \exp(-(x)^2)\cdot\left(1,\sqrt{\frac{2^1}{1!}}x,\sqrt{\frac{2^2}{2!}}x^2,\sqrt{\frac{2^3}{3!}}x^3,\dots,\dots\right)$$

高斯核函数$\boldsymbol{K}(\mathbf{x},\mathbf{x}')$的一般式

$$\boldsymbol{K}(\mathbf{x},\mathbf{x}') = \exp(-\gamma\|\mathbf{x}-\mathbf{x}'\|^2)$$

$$\gamma > 0$$

人工智能与自动化学院

8.5 核函数支撑向量机

高斯核函数SVM

$$K(\mathbf{x},\mathbf{x}') = \exp(-\gamma\|\mathbf{x}-\mathbf{x}'\|^2) \qquad \gamma > 0$$

输入测试样本 $\mathbf{x}$：

$$g_{SVM} = sign(\sum_{SV} \alpha_n y_n K_{\Phi}(\mathbf{x}_n,\mathbf{x}) + b)$$

$$= sign(\sum_{SV} \alpha_n y_n \exp(-\gamma\|\mathbf{x}-\mathbf{x}_n\|^2) + b)$$

- 以所有支撑向量 $\mathbf{x}_n$ 为中心的高斯函数的线性组合
- 也被称之为径向基核函数(Radial Basis Function, RBF)

高斯核函数SVM: 通过求取α_n确定所有支撑向量 $\mathbf{x}_n$ ，构造以支撑向量为中心的高斯函数的线性组合，实现在无穷维空间获得最大间隔分类面

第八讲 对偶支撑向量机与核支撑向量机(*Dual SVM & Kernel SVM*)

8.1 对偶支撑向量机动机(*Motivation of Dual SVM*)

希望不依赖于非线性变换后升维的 $\tilde{d}$

8.2 对偶支撑向量机的拉格朗日分析(*Lagrange Dual SVM*)

通过 KKT 条件 将原问题和对偶问题相关联获得最佳分类面

8.3 求解对偶支撑向量机最佳值(*Solving Dual SVM*)

仍然是二次规划问题，可以方便求解

8.4 对偶支撑向量机讨论(*Messages behind Dual SVM*)

由支撑向量确定最大间隔分类面

8.5 核函数支撑向量机(*Kernel SVM*)

利用核函数避免了对升维后 $\tilde{d}$ 的依赖，且高效求解